

Valutazione della capacità predittiva dei modelli BigVAR: un'applicazione ai consumi energetici e alle emissioni di CO_2 negli Stati Uniti

Tesi di laurea di: Aurora Musitelli

Relatore: Prof. Paolo Maranzano

Correlatore: Prof. Matteo Maria Pelagatti

Università degli Studi di Milano-Bicocca

Anno Accademico 2024/2025

Introduzione: Metodologia

Analisi serie storiche multivariate

- Contesto energetico: serie storiche per l'analisi simultanea di più variabili.
- Studio delle dinamiche strutturali tra diversi processi temporali.

Analisi predittiva

- **Modelli classici (VAR/VARX):** rischio di **sovra-parametrizzazione**. Il numero di parametri cresce rispetto alle variabili (k) e ai ritardi (p), rendendo le stime instabili.
- **Modelli BigVAR (Regolarizzazione):** introduzione vincoli di sparsità per selezionare automaticamente le relazioni rilevanti.
 - ① **HVAR:** struttura gerarchica per variabili endogene.
 - ② **VARX-L:** estensione per l'integrazione di variabili esogene.

Introduzione: Obiettivi di ricerca

1. Valutazione Metodologica

Confronto diretto tra modelli autoregressivi classici (**VAR/VARX**) e il framework regolarizzato **BigVAR** per testare la gestione di sistemi ad alta dimensionalità.

2. Accuratezza Predittiva

Verificare in che misura l'introduzione di *sparsità* riesca a migliorare la stabilità delle stime riducendo l'errore di previsione (**MSFE**).

3. Finalità Applicativa

Produzione di **previsioni robuste** per i consumi energetici e le emissioni di CO₂ negli Stati Uniti, con un orizzonte temporale proiettato al 2025-2030.

Serie Storiche: Dati

Dimensione del campione: $T = 631$ osservazioni mensili per serie storica

Variabili Endogene

Fonte: U.S. Energy Information Administration

- **Frequenza:** Mensile (1973 - 2025)
- **Variabili:** CO₂ ed Energy
- **Settori:**
 - Commerciale, Elettrico, Industriale, Residenziale, Trasporti.
- **Fonti energetiche:**
 - Fossile e Rinnovabile.

Totale: 20 serie storiche endogene

Variabili Esogene

Fonte: Federal Reserve Economic Data

- **Frequenza:** Mensile (1973 - 2025)
- **Variabili:**
 - PIL
 - Indice produzione industriale
 - Popolazione
 - Fornitura nuove case
 - Livello occupazione

Totale: 5 serie storiche esogene

Serie storiche: Pre-processing

Decomposizione serie storica

$$Y_t = \underbrace{S_t}_{\text{Stagionalità}} + \underbrace{T_t}_{\text{Trend}} + \underbrace{C_t}_{\text{Ciclo}} + \underbrace{BS_t}_{\text{Break Strutturali}} + \underbrace{\epsilon_t}_{\text{Errore}}, \quad t = 1, \dots, T$$

1. Rimozione Stagionalità (TRAMO-SEATS)

- Eliminazione valori anomali *outlier*.
- Depurazione dalle fluttuazioni periodiche per ottenere la componente *Seasonally Adjusted*.

↓ Isolamento Trend-Ciclo ↓

2. Hodrick-Prescott Filter with Jumps

- **Separazione Trend-Ciclo:** separazione tra Trend di lungo periodo (T_t) e Ciclo economico (C_t).
- **Filtro HPJ:** identifica i "jumps" ovvero break strutturali.
- **Output:** si ottiene **componente ciclica stazionaria** per garantire validità delle stime BigVAR.

Serie storiche: Ciclo economico

Analisi Serie Storiche per fonte e settore

Componente ciclica




Figura 1: Componenti Cicliche (Emissioni CO₂ vs Energia)

Valutazione: Rolling-Expanding Window

- **Data Split:** suddivisione temporale serie storiche ($T = 631$ osservazioni).




Figura 2: Strategia di valutazione (Nicholson et al., 2017)

Training (70%)

Gen 1973 → Set 2009

Stima dei parametri iniziali sul primo blocco di dati storici.

Rolling Validation (20%)

Ott 2009 → Mar 2020

Selezione dei ritardi p e parametro λ tramite *one-step-ahead*.

Test (10%)

Apr 2020 → Lug 2025

Valutazione finale della capacità predittiva tramite metrica MSFE.

Modello VAR: Definizione e complessità

Equazione del modello Vector autoregression $VAR_k(p)$

$$\mathbf{y}_t = \boldsymbol{\nu} + \sum_{\ell=1}^p \boldsymbol{\Phi}^{(\ell)} \mathbf{y}_{t-\ell} + \mathbf{u}_t, \quad \mathbf{u}_t \sim WN(0, \boldsymbol{\Sigma}_u)$$

Problema della dimensionalità

- **Parametrizzazione:** per $k = 10$ variabili e $p = 12$ ritardi (1 anno), il sistema richiede la stima di $k(1 + kp) = 1210$ **parametri** totali.
- **Stima OLS:** complessità insostenibile, inaffidabile stima classica dei minimi quadrati.
- **Benchmark:** stima modello VAR con $p = 6$ ritardi per quantificare il valore aggiunto della regolarizzazione BigVAR.

Regolarizzazione HVAR: soluzione BigVAR

Funzione obiettivo penalizzata (Nicholson et al., 2017)

$$\min_{\nu, \Phi} \underbrace{\sum_{t=1}^T \left\| y_t - \nu - \sum_{\ell=1}^p \Phi^{(\ell)} y_{t-\ell} \right\|_2^2}_{\text{Funzione di perdita}} + \underbrace{\lambda (\mathcal{P}_y(\Phi))}_{\text{Regolarizzazione}}$$

- **Strutture Hierarchical Group Lasso:** strutture gerarchiche temporali di complessità.
 - ① **Componentwise:** raggruppa i ritardi a blocchi per variabile;
 - ② **Own/Other:** distingue l'influenza della variabile su sé stessa e quella verso le altre;
 - ③ **Elementwise:** la più granulare, valuta ogni singolo coefficiente.
- **Rolling Validation:** selezione automatica di λ che minimizza l'errore di previsione (MSFE).

Sparsity Pattern: Struttura Componentwise




Figura 3: Emissioni CO₂ (struttura componentwise)




Figura 4: Consumi energetici (struttura componentwise)

- **Fonti Fossili:** struttura densa e interconnessa, con alta persistenza storica.
- **Fonti Rinnovabili:** struttura sparsa e segmentata, poco influenzata dal resto del sistema.

Nota: In un contesto puramente endogeno, il sistema è guidato dalle fonti fossili, fonti rinnovabili seguono dinamiche isolate.

Impulse Response Functions (IRF)

HVAR IRF: Fossile_Commercial

Shock su Energy -> Risposta CO₂ (Bande 95%)




Figura 5: Risposta CO₂ a shock Energy Fossile

HVAR IRF: Rinnovabile_Commercial

Shock su Energy -> Risposta CO₂ (Bande 95%)




Figura 6: Risposta CO₂ a shock Energy Rinnovabile

- **Dinamica Fossili:** risposta immediata, le emissioni restano elevate e mostrano una dinamica persistente.
- **Dinamica Rinnovabili:** un impatto iniziale trascurabile la risposta crolla a zero, la regolarizzazione azzerla la trasmissione dello shock.

Modello VARX: Definizione e complessità

Equazione del modello Vector autoregression with Exogenous variables $VARX_{k,m}(p, s)$

$$\mathbf{y}_t = \boldsymbol{\nu} + \sum_{\ell=1}^p \boldsymbol{\Phi}^{(\ell)} \mathbf{y}_{t-\ell} + \sum_{j=1}^s \boldsymbol{\beta}^{(j)} \mathbf{x}_{t-j} + \mathbf{u}_t, \quad \mathbf{u}_t \sim WN(0, \boldsymbol{\Sigma}_u)$$

Problema della dimensionalità

- **Parametrizzazione:** per $k = 10$ variabili endogene con $p = 12$ ritardi, $m = 5$ variabili esogene con $s = 6$ ritardi il sistema richiede la stima di $k(1 + kp + ms) = \mathbf{1510}$ **parametri**.
- **Stima OLS:** complessità insostenibile, inaffidabile stima classica dei minimi quadrati.
- **Vantaggio:** permette di includere variabili macroeconomiche che influenzano la domanda del sistema energetico.

Regolarizzazione VARX-L

Funzione obiettivo penalizzata (Nicholson et al., 2017)

$$\min_{\nu, \Phi, \beta} \underbrace{\sum_{t=1}^T \left\| y_t - \nu - \sum_{\ell=1}^p \Phi^{(\ell)} y_{t-\ell} - \sum_{j=1}^s \beta^{(j)} x_{t-j} \right\|_2^2}_{\text{Funzione di perdita}} + \underbrace{\lambda_1 \mathcal{P}_y(\Phi) + \lambda_2 \mathcal{P}_x(\beta)}_{\text{Regolarizzazione}}$$

- **Strutture VARX-Lasso:** strutture gerarchiche temporali di complessità.
 - ① **Lag Lasso:** raggruppa tutti i coefficienti associati allo stesso ritardo trattandoli come unica unità .
- **Rolling Validation:** selezione automatica di λ_1 controlla sparsità delle dinamiche interne (Energy e CO₂) e λ_2 seleziona variabili esogene rilevanti.

Risultati: periodo di test

Confronto: Serie storica vs Previsioni puntuali periodo di test




Figura 7: Emissioni CO₂ Rinnovabile Industriale



Figura 8: Energia consumata Fossile Trasporti

— Serie Storica

— HVAR

— VARX-L

- **Fonti Rinnovabili:** modello **VARX-L** cattura i picchi grazie alle variabili esogene esterne.
- **Fonti Fossili:** dinamica persistente, la storia passata è il principale driver predittivo.

Evidenza: variabili esogene hanno un beneficio sulle fonti rinnovabili.

Risultati: Confronto Performance MSFE

Serie Storica	Consumi energetici (MSFE)				Emissioni CO ₂ (MSFE)			
	VAR	HVAR	VARX	VARX-L	VAR	HVAR	VARX	VARX-L
<i>Fonti Fossili</i>								
Industrial	3567.39	4154.15	3118.86	4092.46	29.99	27.54	29.31	26.19
Commercial	1316.99	995.96	1391.28	941.97	3.69	2.90	3.92	2.80
Residential	5782.23	3833.56	6124.90	3687.58	14.95	9.90	16.21	9.58
Electric Power	21992.02	14466.72	21495.24	14103.77	109.17	80.07	108.81	79.26
Transportation	2825.57	2628.86	2966.02	2341.93	32.43	30.40	32.00	28.82
<i>Fonti Rinnovabili</i>								
Industrial	52.80	71.19	67.00	56.48	0.22	0.19	0.24	0.14
Commercial	0.24	0.35	0.24	0.24	0.01	0.01	0.01	0.01
Residential	1.99	2.46	2.26	1.12	0.01	0.01	0.01	0.01
Electric Power	90.76	86.46	93.90	64.07	0.01	0.03	0.01	0.01
Transportation	33.36	52.08	31.16	41.82	0.08	0.14	0.08	0.11

Tabella 1: Sintesi dell'errore quadratico medio di previsione (MSFE)

Nota: VARX-L modello migliore, errore minimo nella maggior parte dei settori.

Previsioni Future (2025-2030)

Wild Block Bootstrap con 1000 repliche




Figura 9: Previsioni (2025-2030)

Conclusioni e sviluppi futuri

Contributo Metodologico

- **Pulizia del segnale:** utilizzo del filtro **HPJ** è stato determinante per neutralizzare i break strutturali e isolare il puro ciclo economico.
- **Gestione complessità:** regolarizzazione **BigVAR** non solo una scelta tecnica, ma una necessità metodologica per gestire il problema della sovra-parametrizzazione.

Transizione monitorabile

- **Validazione statistica:** transizione energetica emerge come processo teorico e monitorabile nel tempo.

Sviluppi futuri

- **Ricostruzione serie:** estensione del forecasting all'intera dinamica delle componenti latenti (trend, stagionalità e ciclo).

Grazie
dell'attenzione!