

UNIVERSITÀ DEGLI STUDI DI MILANO-BICOCCA

Scuola di Economia e Statistica

Corso di laurea Magistrale in

SCIENZE STATISTICHE ED ECONOMICHE



**Valutazione della capacità predittiva dei modelli BigVAR:
un'applicazione ai consumi energetici e alle emissioni di CO₂ negli Stati Uniti**

Relatore: Prof. Paolo Maranzano

Correlatore: Prof. Matteo Maria Pelagatti

Tesi di Laurea di:

Aurora Musitelli

Matr. N. 856741

Anno Accademico 2024/2025

Indice

Indice	1
Introduzione	1
Capitolo 1: Fondamenti teorici e modelli di riferimento	3
1.1 Modelli VAR e VARX per serie storiche multiple	3
1.2 Regolarizzazione nei modelli VAR: la struttura HVAR	6
1.3 Regolarizzazione nei modelli VARX: la struttura VARX-L	9
1.4 Modellazione ad alta dimensionalità: BigVAR e tecniche di validazione	11
Capitolo 2: Dati e analisi esplorativa.....	14
2.1 Dati: consumi energetici ed emissioni di CO ₂	14
2.2 Analisi esplorativa: persistenza e test di stazionarietà	18
2.3 Definizione delle variabili esogene	23
Capitolo 3: Metodologia di previsione multivariata	25
3.1 Specifiche e strutture dei modelli multivariati	25
3.2 Applicazione modelli VAR e regolarizzazione HVAR	27
3.2.1 Procedura di stima del modello VAR.....	27
3.2.2 IRF (Impulse Response Functions) di VAR.....	30
3.2.3 Regolarizzazione HVAR	33
3.2.4 IRF (Impulse Response Functions) di HVAR	39
3.3 Applicazione modelli VARX e regolarizzazione VARX-L.....	42
3.3.1 Procedura di stima del modello VARX	42
3.3.2 Regolarizzazione VARX-L	44
Capitolo 4: Risultati e discussione	46
4.1 Confronto modelli e implicazioni pratiche	46
4.2 Previsioni dei consumi energetici ed emissioni di CO ₂	50
Conclusioni	53
Bibliografia	55
Appendice A: Risultati analisi esplorativa serie storiche	57
Appendice B: Metodologia BigVAR.....	59
Appendice C: Bootstrap Forecasting	62

Introduzione

Le serie storiche multivariate rappresentano una tipologia di dati molto significativi nella statistica applicata poiché consentono di capire e prevedere il pattern e la trasformazione di più variabili che vengono misurate e osservate attraverso un indice, in questo caso l'indice temporale. Grazie all'analisi di serie storiche non solo si può osservare il comportamento di un singolo processo, ma risulta possibile intersecare le diverse dinamiche che si creano tra processi temporali differenti: questo risulta rilevante in ambiti come l'economia, l'analisi energetica e tanti altri dove le variabili interagiscono reciprocamente su molteplici e differenti livelli. Tuttavia, per gestire le analisi di serie storiche multivariate possono sorgere dei problemi di sovra-parametrizzazione quando il numero di variabili cresce rapidamente e con loro aumentano i ritardi temporali con una conseguente perdita di stabilità, un possibile overfitting e riduzione della capacità predittiva. Per rispondere a diverse criticità, la letteratura recente ha proposto metodologie basate sulla regolarizzazione che introducono vincoli di sparsità e strutture gerarchiche al fine di selezionare automaticamente le dipendenze più rilevanti nei diversi modelli; tra i contributi più significativi emergono Medeiros e Mendes (2016), che dimostrano la validità dell'utilizzo Lasso in contesti autoregressivi ad alta dimensione e i contributi di Nicholson, Matteson, Bien e Wilms (2017, 2020) che propongono i modelli per serie storiche multivariate con le loro rispettive regolarizzazioni HVAR e VARX-L, gli stessi autori hanno sviluppato il pacchetto BigVAR per il software statistico R, che rende queste metodologie applicabili a grandi set di dati. Il presente lavoro di tesi vuole essere collocato in questa cornice metodologica, utilizzando i modelli classici per serie storiche multivariate confrontandoli con i modelli regolarizzati per applicarli a dati reali relativi ai consumi energetici e le conseguenti emissioni di anidride carbonica (CO_2) negli Stati Uniti, per diversi settori produttivi e fonti energetiche in modo da analizzare le differenti dinamiche energetiche che si sono create e modificate nel corso del tempo. Questa cornice si sviluppa in un contesto che fa emergere diversi aspetti intrinseci delle attività umane, per questo, i due obiettivi principali del seguente lavoro di tesi sono: da un lato, produrre previsioni dei consumi energetici e delle emissioni di CO_2 nei diversi livelli di aggregazione settoriale e per fonte energetica. Dall'altro lato, valutare in che misura i modelli regolarizzati possono migliorare i limiti dei modelli VAR tradizionali in termini di stabilità e accuratezza per sistemi complessi.

Il lavoro di tesi si articola in quattro capitoli principali così suddivisi: nel primo capitolo vengono esposte le basi teoriche dei modelli VAR / VARX e introduce le sue estensioni regolarizzate HVAR / VARX-L, nonché le procedure di validazione adottate nel pacchetto BigVAR che è stato ampiamente utilizzato per le analisi nel software R. Il secondo capitolo si concentra sull'analisi preliminare delle serie storiche multivariate relative ai dati sui consumi energetici e conseguenti emissioni di anidride carbonica (CO₂) ed espone i principali risultati dell'analisi esplorativa, di distribuzione dei dati e dei test di stazionarietà per le serie storiche, costruendo le necessarie basi per poter trattare e applicare i modelli nel capitolo successivo. Il terzo capitolo affronta la metodologia multivariata dei modelli VAR / VARX e le loro estensioni regolarizzate HVAR / VARX-L, trattando in maniera approfondita la selezione dei parametri, le metriche di performance dei modelli e le principali scelte di modellazione tenendo conto delle implicazioni economiche. Infine, nel quarto capitolo si mostrano le conclusioni e i risultati principali ottenuti attraverso il confronto tra i modelli, comparandone le performance ed esplorando le previsioni future dei consumi energetici e delle emissioni di anidride carbonica implementate in un algoritmo di bootstrap forecasting per valutarne l'incertezza in contesti complessi.

In sintesi, si vuole presentare lo sviluppo di strumenti e metodologie già consolidate ad uso dell'analisi e di previsione delle serie storiche multivariate nel contesto energetico-ambientale applicato a dati storici reali. I contenuti sviluppati e i risultati raggiunti possono portare contributi sia sul piano metodologico, in favore della statistica e dell'economia, sia sul piano applicativo presentando elementi ed evidenze rilevanti per una possibile pianificazione della transizione energetica.

Capitolo 1: Fondamenti teorici e modelli di riferimento

1.1 Modelli VAR e VARX per serie storiche multiple

Una serie storica univariata rappresenta una sequenza finita di osservazioni ordinate rispetto al tempo, nello specifico considerando un insieme di istanti temporali $\{t = 1, \dots, T\}$ si indica la serie storica $\mathbf{Y}$ come l'insieme delle osservazioni associate ad ogni istante t : $\mathbf{Y} = \{y_1, \dots, y_T\}$. A partire dalla definizione appena presentata, risulta naturale estendere la definizione univariata alla definizione multivariata: in particolare esaminando più serie storiche contemporaneamente, queste consentono di catturare le diverse dinamiche strutturali tra i vari processi considerati osservando come si modificano rispetto al tempo. In questo contesto i modelli per serie storiche multivariate forniscono un quadro esaustivo per lo studio congiunto di più processi temporali, tra questi, i modelli di Vector Autoregression (VAR) e Vector Autoregression with Exogenous variables (VARX). Originariamente sono stati sviluppati in macroeconomia da Sims (1980), i modelli VAR e le loro estensioni si sono diffuse rapidamente in numerosi ambiti applicativi tra cui economia, finanza, ambito energetico e molti altri grazie alla loro flessibilità e capacità predittiva. Nel presente lavoro di tesi, la notazione matematica adottata per la formalizzazione dei modelli VAR e VARX segue l'approccio di Nicholson, Matteson e Bien (2017, 2020).

Definizione dei modelli VAR (Vector Autoregression)

Un modello VAR può essere interpretato come una regressione multivariata che descrive le dinamiche congiunte tra più variabili endogene che consentono di effettuare una rappresentazione flessibile senza imporre restrizioni strutturali a priori. Sia $\{\mathbf{y}_t \in \mathbb{R}^k\}_{t=1}^T$ un vettore di serie temporali k -dimensionale delle variabili endogene rispetto al tempo t . Un modello VAR_k di ordine p , indicato con $\text{VAR}_k(p)$ è definito da:

$$\mathbf{y}_t = \boldsymbol{\nu} + \sum_{l=1}^p \boldsymbol{\Phi}^{(l)} \mathbf{y}_{t-l} + \mathbf{u}_t, \quad t = 1, \dots, T \quad (1.1)$$

Dove $\boldsymbol{\nu} \in \mathbb{R}^k$ è un vettore $k \times 1$ di intercette, $\{\boldsymbol{\Phi}^{(l)} \in \mathbb{R}^{k \times k}\}_{l=1}^p$ sono le matrici dei coefficienti autoregressivi rispetto al ritardo- l e $\{\mathbf{u}_t \in \mathbb{R}^k\}_{t=1}^T$ è un vettore di errori white noise $\mathbf{u}_t \sim (\mathbf{0}, \boldsymbol{\Sigma}_u)$.

In forma compatta il modello $\text{VAR}_k(p)$ (1.1) può essere riscritto come:

$$\begin{aligned} \mathbf{Y} &= [y_1 \dots y_T] & (k \times T); & \quad \mathbf{\Phi} = [\mathbf{\Phi}^{(1)} \dots \mathbf{\Phi}^{(p)}] & (k \times kp); \\ \mathbf{z}_t &= [y_{t-1}^\top \dots y_{t-p}^\top]^\top & (kp \times 1); & \quad \mathbf{Z} = [z_1 \dots z_T] & (kp \times T); \\ \mathbf{U} &= [u_1 \dots u_T] & (k \times T); & \quad \mathbf{1} = [1 \dots 1]^\top & (T \times 1). \end{aligned}$$

$$\mathbf{Y} = \mathbf{\nu} \mathbf{1}^\top + \mathbf{\Phi} \mathbf{Z} + \mathbf{U}$$

In un contesto classico di bassa dimensionalità in cui $T > kp$ (T numero di osservazioni temporali e kp numero di parametri autoregressivi), è possibile eseguire i minimi quadrati per adattare il modello $\text{VAR}_k(p)$ minimizzando:

$$\min_{\mathbf{\nu}, \{\mathbf{\Phi}^{(l)}\}} \sum_{t=1}^T \left\| \mathbf{y}_t - \mathbf{\nu} - \sum_{l=1}^p \mathbf{\Phi}^{(l)} \mathbf{y}_{t-l} \right\|_2^2 \quad (1.2)$$

Dove $\|\mathbf{a}\|_2 = (\sum_i \mathbf{a}_i^2)^{\frac{1}{2}}$ denota la norma euclidea del vettore generico $\mathbf{a}$. In forma compatta la procedura dei minimi quadrati (1.2) può essere riscritta come:

$$\|\mathbf{Y} - \mathbf{\nu} \mathbf{1}^\top - \mathbf{\Phi} \mathbf{Z}\|_2^2$$

Dove $\|\mathbf{A}\|_2$ denota la norma di Frobenius della matrice $\mathbf{A}$, cioè la norma euclidea del vettore ottenuto concatenando tutte le componenti di $\mathbf{A}$. Il numero totale di parametri risulta essere pari a $k \times (1 + kp)$, ciò comporta una crescita rapida della complessità del modello in contesti ad alta dimensionalità.

Definizione dei modelli VARX (Vector Autoregression with Exogenous variables)

Un'estensione naturale del modello $\text{VAR}_k(p)$ è rappresentata dal modello $\text{VARX}_{k,m}(p,s)$, che incorpora le variabili esogene $\{\mathbf{x}_t \in \mathbb{R}^m\}$ le quali influenzano le dinamiche delle variabili endogene. Formalmente, il modello $\text{VARX}_{k,m}(p,s)$ di ordine (p,s) è definito come:

$$\mathbf{y}_t = \mathbf{\nu} + \sum_{l=1}^p \mathbf{\Phi}^{(l)} \mathbf{y}_{t-l} + \sum_{j=1}^s \mathbf{\beta}^{(j)} \mathbf{x}_{t-j} + \mathbf{u}_t, \quad t = 1, \dots, T \quad (1.3)$$

Dove $\mathbf{\nu} \in \mathbb{R}^k$ è un vettore $k \times 1$ di intercette, $\{\mathbf{\Phi}^{(l)} \in \mathbb{R}^{k \times k}\}_{l=1}^p$ sono le matrici dei coefficienti autoregressivi rispetto al ritardo- l , $\{\mathbf{\beta}^{(j)} \in \mathbb{R}^{k \times m}\}_{j=1}^s$ sono le matrici dei coefficienti che

quantificano l'effetto delle variabili esogene ai ritardo- j sul sistema endogeno e $\{\mathbf{u}_t \in \mathbb{R}^k\}_{t=1}^T$ è un vettore di errori white noise $\mathbf{u}_t \sim (\mathbf{0}, \mathbf{\Sigma}_u)$. In forma compatta il modello $\text{VARX}_{k,m}(p,s)$ (1.3) può essere riscritto come:

$$\begin{aligned} \mathbf{Y} &= [y_1 \dots y_T] & (k \times T); & \quad \mathbf{\Phi} = [\mathbf{\Phi}^{(1)} \dots \mathbf{\Phi}^{(p)}] & (k \times kp); \\ \mathbf{z}_t &= [y_{t-1}^\top \dots y_{t-p}^\top]^\top & (kp \times 1); & \quad \mathbf{\beta} = [\mathbf{\beta}^{(1)} \dots \mathbf{\beta}^{(s)}] & (k \times ms); \\ \mathbf{U} &= [u_1 \dots u_T] & (k \times T); & \quad \mathbf{Z} = [z_1 \dots z_T] & (kp \times T); \\ \mathbf{1} &= [1 \dots 1]^\top & (T \times 1); & \quad \mathbf{X} = [x_1 \dots x_T] & (ms \times T). \\ \mathbf{x}_t &= [x_{t-1}^\top \dots x_{t-s}^\top]^\top & (ms \times 1); \end{aligned}$$

$$\mathbf{Y} = \mathbf{v}\mathbf{1}^\top + \mathbf{\Phi}\mathbf{Z} + \mathbf{\beta}\mathbf{X} + \mathbf{U}$$

Il modello $\text{VARX}_{k,m}(p,s)$ spesso viene utilizzato per integrare informazioni esterne rilevanti al problema in esame, per esempio indicatori economici, ed è particolarmente adatto in contesti in cui si intende prevedere un sottoinsieme di serie endogene sfruttando variabili esogene non incluse nel sistema originale. Tuttavia, eredita gli stessi problemi di alta dimensionalità dei modelli $\text{VAR}_k(p)$, aggravati dall'inclusione delle variabili esogene che aumentano ulteriormente lo spazio dei parametri.

La stima dei parametri si ottiene minimizzando:

$$\min_{\mathbf{v}, \{\mathbf{\Phi}^{(l)}\}, \{\mathbf{\beta}^{(j)}\}} \sum_{t=1}^T \left\| \mathbf{y}_t - \mathbf{v} - \sum_{l=1}^p \mathbf{\Phi}^{(l)} \mathbf{y}_{t-l} - \sum_{j=1}^s \mathbf{\beta}^{(j)} \mathbf{x}_{t-j} \right\|_F^2 \quad (1.4)$$

Dove $\|\mathbf{A}\|_F = (\sum_{i,j} \mathbf{a}_{ij}^2)^{\frac{1}{2}}$ denota la norma di Frobenius della matrice $\mathbf{A}$. In forma compatta l'equazione (1.4) può essere riscritta come:

$$\|\mathbf{Y} - \mathbf{v}\mathbf{1}^\top - \mathbf{\Phi}\mathbf{Z} - \mathbf{\beta}\mathbf{X}\|_F^2$$

In questo caso il numero totale di parametri risulta essere pari a $k \times (1 + kp + ms)$.

Dal punto di vista delle applicazioni, i modelli $\text{VAR}(p)$ e $\text{VARX}(p,s)$ quando coinvolgono un numero elevato di variabili e diverse profondità di ritardo (lag), risultano essere sovra-parametrizzati con successivi problemi di instabilità nei ritardi e scarsa capacità di previsione.

Per superare le diverse criticità, la letteratura ha esposto approcci di regolarizzazione che riducono la complessità dei modelli imponendo vincoli di sparsità sui coefficienti: nel caso dei modelli $\text{VAR}_k(p)$ le tecniche di regolarizzazione proposte da Nicholson, Matteson e Bien (2017) si basano sulle strutture gerarchiche dei ritardi, in particolare HVAR e sull'utilizzo delle penalizzazioni HLAG. Mentre per i modelli $\text{VARX}_{k,m}(p,s)$ con variabili esogene, il problema dimensionale è ancora più evidente, in questo caso l'approccio VARX-L proposto da Nicholson, Matteson e Bien (2017) estende il paradigma di regolarizzazione strutturale aggiungendo particolari penalità che consentono di selezionare congiuntamente i ritardi e le relazioni più rilevanti, sia tra le variabili endogene che esogene.

1.2 Regolarizzazione nei modelli VAR: la struttura HVAR

Nella letteratura statistica esistono diversi approcci più o meno diffusi per affrontare il problema della sovra-parametrizzazione dei modelli $\text{VAR}_k(p)$. Nel seguente sottocapitolo si pone l'attenzione sul framework HVAR (Hierarchical Vector Autoregression), introdotto da Nicholson et al. (2017), che si basa sull'utilizzo di penalizzazioni di tipo HLAG (Hierarchical Lag Structures) questo approccio di regolarizzazione consente di costruire modelli facilmente interpretabili e parsimoniosi attraverso una regolarizzazione gerarchica che agisce contemporaneamente su variabili e ritardi. Nello specifico, considerando l'equazione del modello $\text{VAR}_k(p)$ (1.1) con variabili endogene dove il parametro $\phi_{ij}^{(l)}$ all'interno di $\phi^{(l)}$ misura la dipendenza dinamica della i -esima componente di $\mathbf{y}_t$ dalla j -esima componente ritardata di $\mathbf{y}_{t-l}$. Il framework HVAR propone di stimare i parametri del modello minimizzando una funzione di perdita penalizzata:

$$\min_{\mathbf{v}, \{\phi^{(l)}\}} \sum_{t=1}^T \left\| \mathbf{y}_t - \mathbf{v} - \sum_{\ell=1}^p \phi^{(\ell)} \mathbf{y}_{t-\ell} \right\|_2^2 + \lambda (\mathcal{P}_y(\phi)) \quad (1.5)$$

Dove $\|\mathbf{A}\|_2$ denota la norma di Frobenius della matrice $\mathbf{A}$, $\lambda \geq 0$ rappresenta un parametro di regolarizzazione stimato mediante cross-validation sequenziale mentre $\mathcal{P}_y(\phi)$ rappresenta la struttura della penalità di gruppo sui coefficienti endogeni che impone la gerarchia lag-specifica.

In forma compatta l'equazione (1.5) può essere riscritta come:

$$\min_{\mathbf{v}, \{\Phi\}} \left\{ \frac{1}{2T} \|\mathbf{Y} - \mathbf{v}\mathbf{1}^\top - \Phi\mathbf{Z}\|_2^2 + \lambda (\mathcal{P}_y(\Phi)) \right\}$$

La particolarità di HVAR consiste nell'uso di gruppi annidati di coefficienti, costruiti secondo una gerarchia temporale che rispetta l'ordine dei ritardi, questo significa che un coefficiente associato a un determinato ritardo l può essere $\Phi_{ij}^{(l)} \neq 0$ solo se tutti i coefficienti relativi ai ritardi precedenti $(1, \dots, l-1)$ sono anch'essi inclusi nel modello; il seguente vincolo produce una selezione coerente dei ritardi, dove la complessità temporale di ciascuna relazione è determinata in modo automatico.

Per descrivere formalmente le strutture HLAG, si utilizza la seguente notazione per $1 \leq l \leq p$:

$$\begin{aligned} \Phi^{(l:p)} &= [\Phi^{(l)} \dots \Phi^{(p)}] & (k \times k)(p-l+1); \\ \Phi_i^{(l:p)} &= [\Phi_i^{(l)} \dots \Phi_i^{(p)}] & (1 \times k)(p-l+1); \\ \Phi_{ij}^{(l:p)} &= [\Phi_{ij}^{(l)} \dots \Phi_{ij}^{(p)}] & 1 \times (p-l+1). \end{aligned}$$

Per ogni coppia di variabili (i, j) , si definisce la matrice $\mathbf{L}$ maxlag $(k \times k)$ dei ritardi massimi:

$$\mathbf{L}_{ij} = \max\{l : \Phi_{ij}^{(l)} \neq 0\}$$

Dove ciascun $\mathbf{L}_{ij}$ rappresenta il ritardo massimo della variabile $\mathbf{y}_j$ nella regressione della variabile $\mathbf{y}_i$. In particolare, se tutti i coefficienti $\Phi_{ij}^{(l)} = 0$ per tutti i $l = 1, \dots, p$ allora $\mathbf{L}_{ij} = 0$. La matrice $\mathbf{L}$ sintetizza la profondità temporale effettiva delle relazioni dinamiche tra le variabili e in generale non risulta essere simmetrica, ovvero il ritardo massimo con cui $\mathbf{y}_j$ influenza $\mathbf{y}_i$ può differire dal ritardo con cui $\mathbf{y}_i$ influenza $\mathbf{y}_j$. L'obiettivo delle strutture HLAG è proprio quello di stimare questa gerarchia in modo coerente e parsimonioso, esistono numerose strutture HLAG che si possono considerare nel contesto del modello $\text{VAR}_k(p)$, ma in questo caso si considerano le tre strutture presentate da Nicholson et al. (2020) i quali propongono tre varianti fondamentali della penalizzazione HLAG, ciascuna con un diverso livello nella gerarchia dei ritardi.

Nome gruppo	$\mathcal{P}_y(\Phi)$
Componentwise	$\sum_{i=1}^k \sum_{l=1}^p \ \Phi_i^{(l:p)}\ _2$
Own/Other	$\sum_{i=1}^k \sum_{l=1}^p [\ \Phi_i^{(l:p)}\ _2 + \ \Phi_{i,-l}^{(l)}\ _2 + \ \Phi_i^{([l+1]:p)}\ _2]$
Elementwise	$\sum_{i=1}^k \sum_{j=1}^k \sum_{l=1}^p \ \Phi_{ij}^{(l:p)}\ _2$

Tabella 1: Funzioni di penalità HVAR

Componentwise HLAG ogni equazione del sistema, cioè ogni variabile endogena, possiede una propria struttura gerarchica di ritardi, questo significa che tutti i coefficienti relativi alla variabile y_i condividono la stessa profondità temporale massima L_i .

Own/Other HLAG distingue tra i ritardi “propri” (own) $y_{i,t-l}$ e quelli “altrui” (other) $y_{j,t-l}$ dove $i \neq j$. Questo metodo riconosce che una variabile tende ad avere una maggiore dipendenza dai propri ritardi rispetto ai ritardi delle altre serie storiche, al fine di favorire la conservazione dei termini diagonali nelle matrici dei coefficienti.

Elementwise HLAG è la struttura dove ogni coppia (i, j) di variabili possiede la propria gerarchia dei ritardi, risulta essere la versione più flessibile ma anche la più complessa dal punto di vista computazionale perché gestisce un numero di gruppi che cresce con la seguente forma $(k^2 p)$.

Le regolarizzazioni HLAG risultano avere diversi vantaggi rispetto ai tradizionali metodi di regolarizzazione (come il Lasso o il Group Lasso uniforme): il primo vantaggio riguarda l’aspetto di parsimonia strutturata, che in questo contesto può limitare la complessità del modello senza sacrificare la coerenza temporale dei ritardi. Un secondo vantaggio è dato dalla matrice maxlag L che migliora l’interpretabilità del modello e sintetizza le relazioni dinamiche tra le diverse variabili. Il terzo vantaggio riguarda la stabilità predittiva e l’efficienza computazionale che tende a mitigare l’instabilità dei modelli sparsi non strutturati. Infine, il framework HVAR e le conseguenti regolarizzazioni HLAG rappresentano la fondamentale base teorica sviluppata da (Nicholson et al., 2017) per il software R nel pacchetto BigVAR.

1.3 Regularizzazione nei modelli VARX: la struttura VARX-L

Nel seguente sottocapitolo si affrontano le problematiche di sovra-parametrizzazione dei modelli $\text{VARX}_{k,m}(p,s)$ con variabili esogene attraverso la regularizzazione VARX-L (Vector Autoregression with eXogenous variables - with Lasso penalty). Il seguente approccio permette di affrontare la complessità parametrica dei modelli $\text{VARX}_{k,m}(p,s)$, nei quali si devono considerare sia le dinamiche endogene sia gli effetti delle variabili esogene. Considerando l'equazione del modello $\text{VARX}_{k,m}(p,s)$ (1.3), la funzione obiettivo da minimizzare diventa:

$$\min_{\mathbf{v}, \{\boldsymbol{\Phi}^{(l)}\}, \{\boldsymbol{\beta}^{(j)}\}} \sum_{t=1}^T \left\| \mathbf{y}_t - \mathbf{v} - \sum_{l=1}^p \boldsymbol{\Phi}^{(l)} \mathbf{y}_{t-l} - \sum_{j=1}^s \boldsymbol{\beta}^{(j)} \mathbf{x}_{t-j} \right\|_F^2 + \lambda (\mathcal{P}_y(\boldsymbol{\Phi}) + \mathcal{P}_x(\boldsymbol{\beta})) \quad (1.6)$$

Dove $\|\mathbf{A}\|_F = (\sum_{i,j} \mathbf{a}_{ij}^2)^{\frac{1}{2}}$ denota la norma di Frobenius della matrice $\mathbf{A}$, $\lambda \geq 0$ rappresenta un parametro di regularizzazione stimato mediante cross-validation sequenziale mentre $\mathcal{P}_y(\boldsymbol{\Phi})$ rappresenta la struttura della penalità di gruppo sui coefficienti endogeni e $\mathcal{P}_x(\boldsymbol{\beta})$ rappresenta la struttura di penalità di gruppo sui coefficienti esogeni. Entrambi rappresentano funzioni di penalizzazione per incoraggiare modelli parsimoniosi e di struttura specifica.

In forma compatta l'equazione (1.6) può essere riscritta come:

$$\min_{\mathbf{v}, \{\boldsymbol{\Phi}\}, \{\boldsymbol{\beta}\}} \left\{ \frac{1}{2T} \|\mathbf{Y} - \mathbf{v}\mathbf{1}^\top - \boldsymbol{\Phi}\mathbf{Z} - \boldsymbol{\beta}\mathbf{X}\|_F^2 + \lambda (\mathcal{P}_y(\boldsymbol{\Phi}) + \mathcal{P}_x(\boldsymbol{\beta})) \right\}$$

Il framework VARX-L risulta essere un risultato importante dovuto dall'esigenza di non compromettere la stabilità del modello e poter combinare modelli con la presenza di variabili esogene (ad esempio informazioni economiche). In particolare, le penalità introdotte da Nicholson et al. (2017), rappresentano un collegamento tra le tecniche di sparsità Lasso e le più complesse strutture gerarchiche dei modelli HVAR. Per questo il punto da cui partire è il *Basic Lasso* che applica una penalità L_1 (ovvero la somma dei valori assoluti dei coefficienti) alla funzione di errore quadratico medio (MSE). Nello specifico si tratta di un approccio flessibile in grado di produrre modelli parsimoniosi ma con la problematica di non tenere conto della struttura temporale rischiando di annullare coefficienti in modo incoerente, per superare tali limiti sono state introdotte diverse penalizzazioni di gruppo.

Nome gruppo	$\mathcal{P}_y(\boldsymbol{\Phi})$	$\mathcal{P}_x(\boldsymbol{\beta})$
Basic	$\ \boldsymbol{\Phi}\ _1$	$\ \boldsymbol{\beta}\ _1$
Lag	$\sqrt{k^2} \sum_{l=1}^p \ \boldsymbol{\Phi}^{(l)}\ _F$	$\sqrt{k} \sum_{j=1}^s \sum_{i=1}^m \ \boldsymbol{\beta}_{:,i}^{(j)}\ _F$
Own/Other	$\sqrt{k} \sum_{l=1}^p \ \boldsymbol{\Phi}_{on}^{(l)}\ _F + \sqrt{k(k-1)} \sum_{l=1}^p \ \boldsymbol{\Phi}_{off}^{(l)}\ _F$	$\sqrt{k} \sum_{j=1}^s \sum_{i=1}^m \ \boldsymbol{\beta}_{:,i}^{(j)}\ _F$
Sparse Lag	$(1-\alpha)\sqrt{k^2} \sum_{l=1}^p \ \boldsymbol{\Phi}^{(l)}\ _F + \alpha \ \boldsymbol{\Phi}\ _1$	$(1-\alpha)\sqrt{k} \sum_{j=1}^s \sum_{i=1}^m \ \boldsymbol{\beta}_{:,i}^{(j)}\ _F + \alpha \ \boldsymbol{\beta}\ _1$
Sparse Own/Other	$(1-\alpha)(\sqrt{k} \sum_{l=1}^p \ \boldsymbol{\Phi}_{on}^{(l)}\ _F + \sqrt{k(k-1)} \sum_{l=1}^p \ \boldsymbol{\Phi}_{off}^{(l)}\ _F) + \alpha \ \boldsymbol{\Phi}\ _1$	$(1-\alpha)\sqrt{k} \sum_{j=1}^s \sum_{i=1}^m \ \boldsymbol{\beta}_{:,i}^{(j)}\ _F + \alpha \ \boldsymbol{\beta}\ _1$
Endogenous-First	$\mathcal{P}_{y,x}(\boldsymbol{\Phi}, \boldsymbol{\beta}) = \sum_{l=1}^p \sum_{j=1}^k \left(\ \boldsymbol{\Phi}_{j_r}^{(l)}, \boldsymbol{\beta}_{j_r}^{(l)}\ _F + \ \boldsymbol{\beta}_{j_r}^{(l)}\ _F \right)$	

Tabella 2: Funzioni di penalità VARX-L. $\boldsymbol{\Phi}_{on}^{(l)}$ e $\boldsymbol{\Phi}_{off}^{(l)}$ denotato rispettivamente gli elementi diagonali e fuori dalla diagonale della matrice dei coefficienti $\boldsymbol{\Phi}^{(l)}$.

Lag Group Lasso permette di raggruppare tutti i coefficienti $\boldsymbol{\Phi}^{(l)}$ associati allo stesso ritardo (lag) trattandoli come un'unità unica, in questo modo il modello decide se includere o escludere completamente ciascun lag, semplificando la struttura del modello e migliorandone la parsimonia temporale. Un approccio alternativo ma complementare è l'*Own/Other Group Lasso*, che distingue tra i coefficienti “own” ovvero quelli che rappresentano l'effetto di una variabile sui propri ritardi dai coefficienti “other” che misurano l'influenza delle altre variabili del sistema. Questo metodo si basa sull'osservazione empirica che una serie storica tende a dipendere maggiormente dai propri valori passati e, di conseguenza, tende a preservare le componenti diagonali delle matrici dei coefficienti $\boldsymbol{\Phi}^{(l)}$. Un ulteriore metodo è rappresentato dalle versioni sparse, che abbinano le penalità di gruppo con una penalità L_1 applicata ai singoli coefficienti: caso dello *Sparse Lag Group Lasso* o dello *Sparse Own/Other Group Lasso* la selezione dei parametri avviene su due livelli, per primo si decide se includere o escludere l'intero gruppo dei coefficienti poi si selezionano i singoli coefficienti più rilevanti all'interno del gruppo.

L'ultimo approccio relativo *all'Endogenous-First Lasso* stabilisce una gerarchia tra variabili esogene ed endogene, in cui i coefficienti riguardanti le variabili esogene possono apparire nel modello solo se per lo stesso ritardo si trovano già a disposizione i relativi coefficienti delle variabili endogene.

Le seguenti logiche di regolarizzazione presentate vengono estese anche ai coefficienti $\beta^{(j)}$ associati alle variabili esogene ed in questo caso il principio è analogo ma la formulazione delle penalità differisce da quella applicata ai coefficienti endogeni $\phi^{(l)}$, poiché deve tenere conto della diversa dimensionalità e scala delle variabili esogene. Nicholson et al. (2017) propongono quindi versioni simmetriche ma calibrate delle penalità per le componenti endogene ed esogene, bilanciate tramite opportuni fattori di scala $\sqrt{k}$ e $\sqrt{k^2}$ per mantenere coerenza numerica tra i blocchi dei parametri. Nonostante le numerose flessibilità delle penalizzazioni VARX-L, un limite significativo per questo framework è la gestione dell'ordine di ritardo, poiché le penalità presentate in precedenza forniscono la possibilità di scegliere variabili e coefficienti pertinenti ma non includono in modo esplicito una struttura lag-specifica, questo fa sì che il modello risulta essere agnostico verso le profondità temporali necessarie per replicare le dinamiche del sistema.

1.4 Modellazione ad alta dimensionalità: BigVAR e tecniche di validazione

Le analisi statistiche che sono state condotte sul dataset di serie storiche multivariate si posizionano in un contesto di alta dimensionalità per questo, a partire dagli sviluppi teorici presentati nei sottocapitoli precedenti, si è utilizzato il pacchetto BigVAR per il software R degli autori Nicholson et al. (2017) i quali forniscono un ambiente unificato per la stima, la regolarizzazione e la previsione di modelli $\text{VAR}_k(p)$ e $\text{VARX}_{k,m}(p,s)$ e le loro estensioni regolarizzate. L'obiettivo principale del pacchetto è mantenere la stabilità numerica e ridurre la complessità computazionale rendendo possibile la modellizzazione di sistemi multivariati con un numero di parametri che cresce rapidamente rispetto al numero di osservazioni T a disposizione.

Nel contesto del pacchetto BigVAR, la stima avviene minimizzando una funzione di perdita con penalità strutturata, nel caso $\text{VAR}_k(p)$ il problema ha la forma:

$$\min_{\mathbf{v}, \boldsymbol{\Phi}} \left\{ \frac{1}{2T} \|\mathbf{Y} - \mathbf{v}\mathbf{1}^\top - \boldsymbol{\Phi}\mathbf{Z}\|_F^2 + \lambda P_{HLag}(\boldsymbol{\Phi}) \right\} \quad (1.7)$$

Dove $\|\cdot\|_F$ indica la norma di Frobenius, $\mathbf{Y}$ raccoglie le informazioni, $\mathbf{Z}$ rappresenta la matrice dei regressori laggati, $\boldsymbol{\Phi}$ sono i coefficienti, $\lambda \geq 0$ rappresenta il parametro di regolarizzazione stimato mediante cross-validation sequenziale e $P_{HLag}(\boldsymbol{\Phi})$ impone la gerarchia “lag vicini prima di lag lontani” secondo le strutture componentwise, own/other o elementwise.

Nel caso $\text{VARX}_{k,m}(p,s)$, si scompone analogamente in blocchi endogeni ed esogeni:

$$\min_{\mathbf{v}, \boldsymbol{\Phi}, \boldsymbol{\beta}} \left\{ \frac{1}{2T} \|\mathbf{Y} - \mathbf{v}\mathbf{1}^\top - \boldsymbol{\Phi}\mathbf{Z} - \boldsymbol{\beta}\mathbf{X}\|_F^2 + \lambda(\mathcal{P}_y(\boldsymbol{\Phi}) + \mathcal{P}_x(\boldsymbol{\beta})) \right\} \quad (1.8)$$

dove P_y e P_x sono penalità di gruppo (Lag, Own/Other) o sparse-group con eventuale priorità “Endogenous-First” per far entrare le variabili esogene solo quando le variabili endogene allo stesso ritardo risultano attive. In entrambi i casi, uno degli aspetti centrali del pacchetto BigVAR è proprio la stima del parametro di regolarizzazione λ che controlla la parsimonia ed è selezionato in modo coerente con la dipendenza temporale dei dati. Nell’ambito dei modelli analizzati, la scelta del parametro di penalizzazione λ segue un cross-validation sequenziale in una finestra di tuning dedicata $[T_1, T_2]$, dove per ciascun valore della griglia si scorre una finestra mobile (rolling) o espandente (expanding) e ad ogni passo si standardizzano le serie nella finestra (media zero e varianza unitaria). Si stima il modello e si produce la previsione a orizzonte h accumulando la perdita previsiva fuori campione, tipicamente MSFE l’errore quadratico medio di previsione ad h passi. Salvo diversa specificazione che viene impostata, si sceglie $\hat{\lambda}$ come il valore che minimizza l’errore quadratico medio di previsione (MSFE):

$$MSFE(\lambda_i) = \frac{1}{(T_2 - T_1 - h + 1)} \sum_{t=T_1-h+1}^{T_2-h} \left\| \hat{y}_{t+h|t}^{\lambda_i} - y_{t+h} \right\|_2^2 \quad (1.9)$$

Il valore ottimo è quello che minimizza l’errore medio fuori campione nella finestra di tuning; fissato λ si valuta poi il modello su un periodo di test indipendente replicando la catena stima-previsione in rolling.

La standardizzazione per finestra prima della stima evita che la penalità favorisca variabili a scala piccola e migliora la stabilità degli algoritmi utilizzati, inoltre l'adozione di penalità strutturate riduce drasticamente il numero effettivo di coefficienti attivi, rendendo praticabile la stima anche quando $p_{\max}$ (ordine massimo dei ritardi) risulta essere ampio.

Per quanto riguarda le metodologie di valutazione empirica delle previsioni dei modelli presentati, la valutazione delle performance di un modello può essere condotta attraverso la valutazione in-sample o out-of-sample: la valutazione in-sample misura la capacità del modello di adattarsi ai dati utilizzati per la stima ed è utile per verificare coerenza interna e parsimonia, ma non garantisce capacità predittiva quando il numero di parametri potenziali è elevato. La seconda modalità invece riguarda la valutazione out-of-sample, che analizza la capacità predittiva del modello su dati non utilizzati in fase iniziale di stima e porta numerosi vantaggi in caso di analisi forecasting in avanti. Operativamente si distingue tra strategie iterated (previsioni a un passo iterate fino a h) e direct (modelli stimati specificamente per l'orizzonte h) in cui per ciascun orizzonte si costruiscono serie di errori e si sintetizzano con metriche adatte: si utilizzano RMSE (Errore quadratico medio) quanto l'errore è grande in media, MAE (Errore assoluto medio), il MAPE (Errore percentuale medio assoluto) può integrare l'analisi offrendo un'interpretazione percentuale. Nei sistemi multivariati la metrica primaria è MSFE (Errore quadratico medio di previsione) ad h passi, definita come media dei quadrati degli errori di previsione che risulta molto utile quando bisogna confrontare modelli penalizzati da modelli non penalizzati, metrica utile che verrà utilizzata nel corso delle analisi.

Complessivamente gli argomenti esposti riguardanti il disegno di validazione temporale e le metriche delineati in questo capitolo costituiscono il collegamento tra la parte teorica e l'analisi empirica sui dati reali, infatti nei capitoli successivi, tali metodologie verranno applicate ai dati sui consumi energetici e sulle emissioni di CO₂ consentendo un confronto tra i modelli classici VAR / VARX e i modelli penalizzati HVAR / VARX-L.

Capitolo 2: Dati e analisi esplorativa

Dopo aver introdotto nel primo capitolo la parte teorica riguardante la modellazione delle serie storiche multivariate, nel secondo capitolo vengono descritti i dati energetici utilizzati, le analisi esplorative e la fase di pre-processing effettuata per il raggiungimento degli obiettivi di ricerca.

2.1 Dati: consumi energetici ed emissioni di CO₂

I dati energetici utilizzati nel seguente lavoro di tesi provengono dalla U.S. Energy Information Administration (EIA)¹, contengono informazioni mensili sul consumo energetico e quantità di emissioni di anidride carbonica (CO₂) a livello nazionale negli Stati Uniti con suddivisione per settore economico e tipologia di fonte energetica.

Descrizione delle variabili del dataset

Month (Mese) informazione mensile dei dati a livello nazionale negli Stati Uniti che coprono il periodo da gennaio 1973 a luglio 2025 (631 osservazioni mensili).

EnerCons_TrillBTU (Energy) si riferisce alla quantità fisica di energia consumata, espressa in Trillion BTU dove trillion segue la scala corta e corrisponde a 10^{12} BTU. In italiano, questa unità dovrebbe essere indicata come bilione di BTU (nelle analisi si fa riferimento alla scala corta). Un BTU (British Thermal Unit) rappresenta l'energia necessaria per aumentare di 1° Fahrenheit la temperatura di una libbra d'acqua a pressione atmosferica standard.

EmissCO₂_MillMetricTons (CO₂) si riferisce alle emissioni di anidride carbonica associate al consumo di energia, espresse in questo caso in milioni di tonnellate metriche. Una tonnellata metrica equivale a 1.000 chilogrammi e questa misura quantifica l'impatto ambientale dei consumi energetici fornendo una misura diretta delle emissioni generate.

Sector (Settore) i dati considerano cinque settori economici principali tra cui:

1. settore commerciale: consumi energetici di uffici, negozi, scuole e strutture pubbliche;
2. settore energia elettrica: comprende la produzione e la distribuzione di energia elettrica;
3. settore industriale: comprende tutte le attività produttive a livello nazionale;

¹ [U.S. Energy Information Administration \(EIA\)](#)

4. settore residenziale: comprende le abitazioni private e gli edifici pubblici;
5. settore trasporti: rappresentano i consumi legati alla mobilità di diversi trasporti.

Source (Fonte) sono state mantenute esclusivamente le fonti energetiche indicate nella Tabella 3, in quanto ritenute più rilevanti ai fini dell'analisi statistica e sono state suddivise in base alla loro natura Fossile e Rinnovabile.

Sector	Source	Descrizione
<i>Fonti Fossili</i>	Coal	(Carbone) combustibile fossile solido derivato da piante fossilizzate, usato per la produzione di energia elettrica in ambito industriale.
	Petroleum	(Petrolio) miscela naturale di idrocarburi liquidi, estratto per produrre carburanti (benzina, diesel) e materie prime per l'industria chimica.
	Natural Gas	(Gas Naturale) gas fossile costituito da metano utilizzato per riscaldamento, elettricità e industria.
	Motor Gasoline	(Motore a benzina) carburante liquido per autoveicoli, escluso l'etanolo aggiunto.
	Distillate Fuel Oil	(Olio Combustibile Distillato) derivato della raffinazione del petrolio, utilizzato per il riscaldamento, la produzione elettrica e come carburante.
<i>Fonti Rinnovabili</i>	Biomass Energy	(Energia da biomassa) ottenuta dalla combustione di materiali come legno e rifiuti in biocarburanti o biogas per la produzione di elettricità.
	Conventional Hydroelectric Power	(Energia idroelettrica convenzionale) prodotta dal movimento dell'acqua in impianti idroelettrici, alimentati da dighe o corsi d'acqua.
	Wind Energy	(Energia eolica) prodotta dal vento, che aziona le turbine eoliche trasformando l'energia cinetica in elettricità.
	Solar Energy	(Energia solare) generata sfruttando le radiazioni solari tramite pannelli fotovoltaici (elettricità) o collettori solari (usi termici).
	Geothermal Energy	(Energia Geotermica) ottenuta dal calore naturale della terra, utilizzata per la produzione di elettricità e per il riscaldamento.

Tabella 3: Descrizione dei settori economici e delle fonti energetiche

Pre-processing dei dati e analisi valori mancanti

Il dataset importato inizialmente nell'ambiente R è stato riorganizzato in formato “largo” (wide) e suddiviso in due dataset, uno relativo alle emissioni di anidride carbonica “dataCO₂” e l'altro relativo ai consumi energetici “dataENERGY”. In entrambi i dataset le righe rappresentano i mesi compresi tra gennaio 1973 e luglio 2025 mentre le colonne contengono le combinazioni delle variabili nelle forme CO₂_Sector_Source ed Energy__Sector_Source. Per quanto riguarda la prima fase dell'analisi ha riguardato lo studio dei valori mancanti, esaminati tramite una mappa rappresentata nella Figura 1. L'analisi più approfondita ha mostrato che i valori mancanti non sono casuali ma strutturali, ovvero sono presenti in tutte le osservazioni temporali (631 mesi) per specifiche combinazioni di settore economico e fonte energetica. Questa condizione riflette la reale assenza di utilizzo di alcune fonti energetiche in determinati settori economici, di conseguenza non è stata applicata alcuna imputazione dei valori mancanti.




Figura 1: Mappa valori mancanti per fonte energetica e settore

Le colonne contenenti valori mancanti (“NA”) sono state eliminate e nelle Figure 2 e 3 riportate si mostrano le combinazioni di serie storiche effettivamente mantenute dopo la pulizia dei dati: emerge che le combinazioni tra CO₂ ed energia consumata non coincidono perfettamente a livello di settore e fonte, questo significa che alcune coppie presentano dati disponibili solo per una delle due variabili CO₂ o Energy. Per evitare una grossa perdita di informazioni si è scelto di non eliminare tali combinazioni e conducendo separatamente le analisi per Energy e CO₂.




Figura 2: Serie storiche Energy standardizzate per settore e fonte




Figura 3: Serie storiche CO2 standardizzate per settore e fonte

2.2 Analisi esplorativa: persistenza e test di stazionarietà

A questo punto sono state condotte le analisi esplorative delle serie storiche con l'obiettivo di verificare la presenza di componenti non osservabili come il trend, la stagionalità, il ciclo economico e possibili break strutturali per valutarne la loro distribuzione, la persistenza e la stazionarietà dei dati storici.

Analisi descrittiva e box plot settoriali

È stata effettuata l'analisi descrittiva delle serie storiche attraverso i box plot realizzati per ciascun settore economico riportati nelle Figure 4 e 5. Da questi grafici emerge che i principali settori in termini di consumo medio e di variabilità sono quelli dell'energia elettrica, industriale e dei trasporti: il settore dell'energia elettrica presenta la massima dispersione con un numero considerevole di outlier, indicando una forte volatilità legata a variazioni nel mix energetico. Il settore industriale mostra le mediane più elevate per entrambe le variabili (Energy e CO₂). Il settore dei trasporti mostra una dispersione elevata e picchi di outlier significativi che possono essere riconducibili a fluttuazioni nella domanda dei carburanti. Dall'altra parte, i settori commerciale e residenziale mostrano mediane e intervalli interquartili più contenuti rispetto ai primi tre settori con outlier che riflettono picchi stagionali di consumo. Per quanto riguarda l'analisi di correlazione di Pearson tra i consumi di energia e le emissioni di CO₂ si evidenzia un coefficiente prossimo a +1 pari a $r = 0,976$ indicando una relazione lineare molto forte e statisticamente significativa la quale risulta essere coerente con i dati analizzati.




Figura 4: Box plot energia consumata per settore




Figura 5: Box plot emissioni di CO₂ per settore

Analisi distribuzione e test di normalità

Successivamente all'analisi descrittiva, si è analizzato quanto i dati originali delle serie storiche si discostassero da un'ipotetica distribuzione normale attraverso gli istogrammi e i QQ-plot delle variabili CO₂ ed Energy confrontando le distribuzioni delle variabili con la curva normale teorica. A livello di risultati grafici mostrano che, la maggior parte delle serie storiche, presentano distanze significative dalla normalità con asimmetrie e multimodalità. Queste osservazioni sono state confermate anche dai test di normalità effettuati di Jarque-Bera, Shapiro-Wilk e Kolmogorov-Smirnov con valori di p-value < 0.05 , ovvero rifiuto dell'ipotesi nulla di normalità dei dati. Nonostante questi risultati non vicini alla normalità, le tecniche di modellazione BigVAR non richiedono necessariamente l'assunzione di normalità delle distribuzioni quindi si è scelto di non applicare alcun tipo di trasformazione, mantenendo i dati nella loro forma originale. Alcuni esempi di distribuzioni osservati nelle serie storiche:





Figura 6: Istogrammi delle distribuzioni consumo Energy





Figura 7: Istogrammi delle distribuzioni emissioni CO₂

Autocorrelazione e persistenza temporale

Una volta che sono state comprese le caratteristiche più evidenti delle serie storiche si è passato all'analisi di distribuzione della persistenza, in particolare delle funzioni di autocorrelazione (ACF) e autocorrelazione parziale (PACF) le quali risultano essere importanti in questa fase delle analisi. In molte serie si è evidenziato una marcata persistenza temporale con autocorrelazioni positive fino a diversi ritardi, segno di possibili non stazionarietà e quindi presenza di trend e componenti stagionali. Per supportare i risultati dei grafici è stato eseguito il test Portmanteau nella versione Ljung–Box, per diversi ritardi (fino a 36 mesi), che conferma la presenza di autocorrelazione significativa in gran parte delle serie storiche, indicando che i valori passati influenzano in modo sistematico quelli presenti e di conseguenza anche quelli futuri che rendono necessari degli approfondimenti sulla stazionarietà delle serie storiche.

Test di stazionarietà e trasformazioni applicate ai dati

La verifica della stazionarietà delle serie storiche risulta essere un requisito importante per l'applicazione di modelli $\text{VAR}_k(p)$, $\text{VARX}_{k,m}(p,s)$ e di modelli ad alta dimensionalità come evidenziano Medeiros et al. (2016) e Nicholson et al. (2017, 2020), in questo contesto si richiede una stazionarietà in senso debole dove media, varianza e covarianza non dipendono dal tempo e quindi rimangono costanti. Alla luce di questa considerazione per ciascuna combinazione di settore economico e fonte energetica sono state applicate le trasformazioni descritte di seguito per rendere le serie storiche stazionarie: come primo step sono stati individuati i principali break strutturali osservabili nei dati e corrispondenti a eventi macroeconomici globali e nazionali che hanno influenzato il sistema energetico degli Stati Uniti e risultano visibili nelle serie storiche analizzate. Si sono evidenziati la crisi petrolifera e politiche di risparmio energetico (anni 1979–1983), la liberalizzazione del mercato elettrico e la crescita economica (1997–2001), la crisi finanziaria globale (2008-2009) e più di recente, la pandemia di COVID-19 (2020). Successivamente come secondo step si è verificata la stazionarietà delle serie storica attraverso l'utilizzato del test di Dickey-Fuller aumentato (ADF) e il test di stazionarietà KPSS: si osserva che la maggior parte delle serie storiche presenta non stazionarietà per questo motivo si è passati alla decomposizione delle serie storiche analizzate.

Situazione di partenza delle serie storiche:

$$Y_t = T_t + S_t + C_t + BS_t + \varepsilon_t, \quad \forall t = 1, \dots, T \quad (2.1)$$

Dove T_t rappresenta il trend, S_t la stagionalità, C_t il ciclo economico, BS_t i break strutturali e ε_t cattura la dinamica stocastica delle serie storiche. La decomposizione delle serie storiche è stata effettuata in due passaggi principali:

1. Rimozione della componente stagionale adottando il metodo TRAMO-SEATS sviluppato dalla Banca di Spagna (Gomez and Maravall, 1996) implementato tramite il pacchetto RJDemetra in R. In particolare, questo approccio a livello metodologico è composto da due moduli TRAMO (Time Series Regression with ARIMA Noise, Missing Observations, and Outliers) che si occupa di stimare un modello reg-ARIMA, mentre il modulo di SEATS (Signal Extraction in ARIMA Time Series) utilizza il modello ARIMA stimato da TRAMO per decomporre la serie storica nelle sue componenti trend, ciclo economico, stagionalità ed errore.

2. Successivamente sulle serie destagionalizzate è stato applicato il filtro HPJ per separare il trend dal ciclo economico (quest'ultimo risulta essere stazionario) e rimuovere i break strutturali. Si è utilizzato il filtro HPJ (Hodrick–Prescott with Jumps) tramite la libreria jumps, approfondito dagli autori Maranzano e Pelagatti (2025), in modo tale da lavorare su serie storiche cicliche economiche per indagare il ruolo dei consumi energetici nel determinare le emissioni di CO₂. Il filtro HPJ rappresenta un'estensione del filtro Hodrick–Prescott (HP), progettato per affrontare una criticità fondamentale quella di gestire i break strutturali, introducendo una penalizzazione L1 sulle variazioni del trend che consente l'identificazione automatica dei break strutturali, questa procedura di stima risolve il seguente problema di ottimizzazione:

$$\min_{T_t} \left[\sum_{t=1}^T (Y_t - T_t)^2 + \lambda \sum_{t=2}^{T-1} (\Delta^2 T_t)^2 + \gamma \sum_{t=2}^T |\Delta T_t| \right] \quad (2.2)$$

Il primo termine garantisce l'aderenza della stima alle serie storiche, il secondo termine penalizza curvature eccessive rendendo i trend più lisci (come nel filtro HP classico) e il terzo è una penalizzazione (L1 tipo Lasso) la quale porta ad annullare alcune variazioni del trend mantenendo solo i salti improvvisi necessari.

A seguito della rimozione della stagionalità, del trend e dei break strutturali mediante le tecniche esposte, le serie storiche utilizzate nelle analisi successive coincidono con la componente ciclica economica stazionaria C_t .

$$Y_t^* = C_t + \varepsilon_t, \quad \forall t = 1, \dots, T \quad (2.3)$$

Come passaggi successivi sono stati ristimati i test ADF i quali confermano che tutte le serie storiche relative alle emissioni di CO₂ e le serie storiche relative ai consumi energetici hanno raggiunto la stazionarietà, mostrando statistiche test inferiori ai valori critici di riferimento. L'applicazione delle trasformazioni descritte ha permesso di ottenere due dataset finali pre-processati ([grafici in Appendice A](#)) che risultano essere più stabili e inoltre le serie sono state aggregate per fonte energetica Fossile e Rinnovabile, mantenendo la distinzione per settore, ottenendo 10 serie storiche aggregate (5 settori $\times$ 2 categorie).

$$\mathbf{y}_t^{CO_2} = \begin{bmatrix} CO2_{Fossile_Industrial,t} \\ CO2_{Fossile_Commercial,t} \\ CO2_{Fossile_Residential,t} \\ CO2_{Fossile_ElectricPower,t} \\ CO2_{Fossile_Transportation,t} \\ CO2_{Rinnovabile_Industrial,t} \\ \vdots \\ \vdots \\ \vdots \\ CO2_{Rinnovabile_Transportation,t} \end{bmatrix}, \quad \mathbf{y}_t^{Energy} = \begin{bmatrix} Energy_{Fossile_Industrial,t} \\ Energy_{Fossile_Commercial,t} \\ Energy_{Fossile_Residential,t} \\ Energy_{Fossile_ElectricPower,t} \\ Energy_{Fossile_Transportation,t} \\ Energy_{Rinnovabile_Industrial,t} \\ \vdots \\ \vdots \\ \vdots \\ Energy_{Rinnovabile_Transportation,t} \end{bmatrix} \quad (2.4)$$

Si sono ottenuti così i seguenti vettori dove $\mathbf{y}_t^{CO_2} \in \mathbb{R}^{10 \times 1}$ e $\mathbf{y}_t^{Energy} \in \mathbb{R}^{10 \times 1}$, mentre i due dataset completi rappresentano le matrici temporali dei vettori $\mathbf{y}_t$ nel tempo: $\mathbf{Y}^{CO_2} \in \mathbb{R}^{631 \times 10}$ e $\mathbf{Y}^{Energy} \in \mathbb{R}^{631 \times 10}$.

2.3 Definizione delle variabili esogene

Successivamente alla fase di pre-processing iniziale delle serie storiche, i due dataset finali relativi ai consumi energetici e alle emissioni di anidride carbonica (CO₂) non rappresentano più rispettivamente le quantità originarie espresse in Trillion BTU e milioni di tonnellate metriche, ma identificano le deviazioni mensili rispetto alla componente trend di lungo periodo una volta rimosse la componente stagionale e i break strutturali. In questo caso ogni serie contenuta nei dataset dataENERGY e dataCO2 riflette le fluttuazioni cicliche economiche attorno al trend stimato dove i valori positivi indicano un livello superiore al trend di lungo periodo, mentre valori negativi segnalano un livello inferiore rispetto al trend. Le variabili descritte rappresentano le *variabili endogene* a cui sono state integrate nel sistema una serie di *variabili esogene*, provenienti dalla Federal Reserve Economic Data (FRED)², dati di natura macroeconomica selezionate in base ai fattori econometrici che potrebbero influenzare la domanda e la produzione di energia che verranno poi utilizzate per i modelli VARX_{k,m}(p,s).

Variabile	Significato	Possibile utilizzo
<i>GDP_USA</i>	Prodotto Interno Lordo	Espresso in miliardi di dollari e interpolato linearmente su base mensile, rappresenta la misura sintetica dell'attività economica complessiva.
<i>IPI_USA</i>	Indice Produzione Industriale	Misura l'andamento dell'attività manifatturiera, fornendo quindi una misura diretta dell'utilizzo di energia nei processi produttivi (indice base 2017 = 100).
<i>Pop_USA</i>	Popolazione	Rappresenta la popolazione totale residente negli Stati Uniti (in milioni di persone).
<i>NewHouse_USA</i>	Fornitura di nuove case	Calcolata come rapporto tra abitazioni invendute e vendite mensili, rappresenta un indicatore del ciclo immobiliare.
<i>Occupation_USA</i>	Livello di occupazione	Misura il numero di occupati negli Stati Uniti (in milioni); rappresenta una misura delle condizioni del mercato del lavoro.

Tabella 4: Descrizione delle variabili esogene

² [Federal Reserve Economic Data \(FRED\)](#)

Le variabili esogene sono state rese stazionarie, dove necessario, allo stesso modo delle variabili endogene in modo da garantirne la stazionarietà e assicurare una penalizzazione omogenea dei coefficienti nelle stime regolarizzate (Nicholson et al., 2017; Medeiros, 2016). In particolare, tutte le variabili macroeconomiche utilizzate risultano essere già seasonally adjusted, ad eccezione della popolazione, a cui è stata applicata la destagionalizzazione tramite TRAMO-SEATS. A tutte le variabili destagionalizzate è stato poi applicato il filtro HPJ, in modo da estrarre la componente ciclica, di conseguenza anche le variabili esogene utilizzate nel modello rappresentano deviazioni temporanee rispetto al trend di lungo periodo.

Nel complesso, l'introduzione delle variabili esogene permetterà di costruire una gerarchia temporale che andrà a collegare le fonti energetiche e i settori economici al contesto macroeconomico statunitense, per consentire di analizzare in modo congiunto le relazioni dinamiche tra consumi energetici, emissioni di anidride carbonica e variabili macroeconomiche.




Figura 8: Variabili esogene (componenti cicliche e standardizzate)

Capitolo 3: Metodologia di previsione multivariata

Nel terzo capitolo verranno applicati i modelli di previsione multivariata BigVAR, descritti a livello teorico nel primo capitolo, per valutare la capacità predittiva dei modelli e le dinamiche tra le emissioni di CO₂ e i consumi energetici negli Stati Uniti, descrivendo nel dettaglio i passi operativi implementati in R, le scelte modellistiche adottate e i criteri di valutazione dei modelli.

3.1 Specifiche e strutture dei modelli multivariati


Per poter utilizzare i dati pre-processati descritti nel secondo capitolo ai fini della modellazione, le serie storiche sono state trasformate in matrici multivariate tramite la funzione `as.matrix()` di R, coerenti con la struttura prevista dei modelli VAR / VARX e le loro estensioni con regolarizzazioni implementate nel pacchetto BigVAR (che accetta esclusivamente matrici). L'obiettivo è quello di osservare la capacità previsiva dei modelli di serie storiche nell'evoluzione congiunta dei consumi energetici e le relative emissioni di CO₂ negli Stati Uniti. Sono stati costruiti due insiemi di variabili endogene Y_t :

Modello CO₂: matrice $\mathbf{Y}^{CO_2} \in \mathbb{R}^{631 \times 10}$, contenente le dieci serie storiche di emissioni di CO₂ aggregate per settore e fonte energetica (fossile e rinnovabile).

Modello ENERGY: matrice $\mathbf{Y}^{Energy} \in \mathbb{R}^{631 \times 10}$, contenente i consumi energetici aggregati per settore e fonte energetica (fossile e rinnovabile).

Le variabili macroeconomiche esterne sono state raccolte in una matrice X_t , trasformata anch'essa in formato numerico: $\mathbf{X} \in \mathbb{R}^{631 \times 5}$ dove $k = 5$ rappresenta il numero di variabili esogene (PIL, produzione industriale, occupazione, popolazione, nuove costruzioni residenziali).

Il processo di modellazione può essere sintetizzato dal seguente schema:



Per ciascun modello stimato sono stati considerati fino a 12 ritardi (lag) endogeni per i modelli $\text{VAR}_k(p)$ corrispondenti ad un anno di dinamica temporale considerando che i dati sono mensili e fino a 6 ritardi esogeni per i modelli $\text{VARX}_{k,m}(p,s)$, così da consentire alle variabili macroeconomiche di influenzare la previsione secondo una logica di risposta ritardata. Considerando l'assenza di regolarizzazione un modello $\text{VAR}_k(p)$ con $k = 10$ variabili e $p = 12$ ritardi richiederebbe la stima di $k^2p = 10 \times 10 \times 12 = 1200$ coefficienti per la parte endogena a cui si possono aggiungere i coefficienti relativi alle componenti esogene nel caso $\text{VARX}_{k,m}(p,s)$. Questa persistente complessità genera problemi noti in letteratura per i modelli tra cui sovra-parametrizzazione, multicollinearità e peggioramento delle performance previsive out-of-sample (Nicholson et al., 2017; Medeiros et al., 2016), per evidenziare i limiti e motivare l'adozione dei metodi BigVAR, il flusso di lavoro del capitolo prevede tre passaggi principali:

1. Stima dei modelli $\text{VAR}_k(p)$ e analisi delle funzioni IRF (Impulse Response Functions) per osservare l'impatto dei consumi energetici sulle emissioni di anidride carbonica;
2. Stima dei modelli penalizzati HVAR, che impongono sparsità e selezionano automaticamente solo le relazioni significative e analisi funzioni IRF (Impulse Response Functions) penalizzate;
3. Introduzione delle variabili macroeconomiche nel modello $\text{VARX}_{k,m}(p,s)$ e stima dei modelli penalizzati VARX-L.

3.2 Applicazione modelli VAR e regolarizzazione HVAR

Per garantire confrontabilità tra i modelli VAR classici e i modelli HVAR penalizzati sono stati stimati per entrambe le classi di variabili, CO₂ ed ENERGY, la stessa suddivisione temporale 70%, 20%, 10% attraverso il metodo Rolling-expanding Window Out of Sample Evaluation come illustrato nella Figura 9: l'utilizzo di questa procedura permette di rispettare la struttura temporale delle serie storiche risultando particolarmente adatta alla valutazione di modelli di previsione in contesti complessi e dinamici.




Figura 9: [Rolling-expanding Window Out of Sample Evaluation](#)

3.2.1 Procedura di stima del modello VAR

Un modello VAR dal punto di vista statistico specifica ogni singola variabile come funzione dei ritardi (lag) di tutte le variabili endogene, catturando le dipendenze dinamiche all'interno del sistema. Mentre dal punto di vista interpretativo permette di identificare come uno shock in un determinato settore e per una determinata fonte si trasmetta nel tempo sulle emissioni di CO₂, fornendo una rapida rappresentazione dell'evoluzione del sistema energetico studiato. La procedura di stima che è stata adottata segue la seguente suddivisione temporale:

- $T_0 \approx 1$ prima osservazione disponibile;
- Training ($1:T_1$) $\approx 70\%$ del campione utilizzato per stimare i modelli iniziali e per inizializzare la procedura di rolling forecast;
- Rolling cross-validation ($T_1 + 1:T_2$) $\approx 20\%$ del campione utilizzato per la selezione del numero ottimale di lag p tramite previsioni one-step-ahead;
- Test out-of-sample ($T_2 + 1:T$) $\approx 10\%$ del campione che è stato utilizzato per la valutazione finale delle performance previsive.

La selezione del lag p ottimale è stata effettuata tramite rolling-expanding sul periodo $T_1 + 1:T_2$ e i risultati, mostrati nelle Figure 10 e 11, si sono riportati gli andamenti del valore RMSE (Root Mean Squared Error) medio al variare del lag p per le due matrici $\mathbf{Y}^{CO_2}$ e $\mathbf{Y}^{Energy}$. Per entrambi i sistemi, passando dal valore $p = 1$ a $p = 6$, si osserva una riduzione dell'RMSE medio raggiungendo il minimo globale per lag più elevati (intorno a $p = 12$) ma a costo di una forte perdita di stabilità del modello poiché le radici caratteristiche massime del polinomio autoregressivo si avvicinano all'unità e superano la soglia di stazionarietà per $p \geq 11$, la verifica è stata effettuata tramite funzione di controllo delle radici del modello VAR (package vars).




Figura 10: RMSE medio al variare del lag p




Figura 11: RMSE medio al variare del lag p

Quindi per conciliare diversi elementi come la buona capacità previsiva e la parsimonia si è scelto di fissare il lag p ottimale pari a 6, che rappresenta un minimo locale dell'RMSE medio e garantisce al tempo stesso radici caratteristiche all'interno del cerchio unitario.

A questo punto il modello VAR_k (6) viene ristimato sull'intervallo $1:T_2$ e le previsioni out-of-sample vengono effettuate tramite la procedura rolling-expanding sul periodo $T_2 + 1:T$, ottenendo previsioni one-step-ahead per tutte le 10 serie storiche dei sistemi CO_2 ed ENERGY. I risultati sintetici sono riportati nella Tabella 5, i quali fanno capire quanto il modello sia in grado di prevedere, si osservano i limiti della modellizzazione non penalizzata in un sistema con più variabili:

- Per l'energia consumata, le serie storiche fossili presentano livelli di errori più elevati ($RMSE \approx 148$ per il settore Electric Power e $RMSE \approx 76$ per il settore Residential) riflettendo una forte volatilità dei consumi energetici. Le componenti rinnovabili mostrano RMSE assoluti molto più contenuti, ma valori di RMSE relativi non banali, segnalando che la dinamica delle rinnovabili è meno volatile in termini di livello ma difficile da prevedere.
- Per le emissioni di CO_2 i risultati sono analoghi ad Energy, i settori fossili Electric Power e Transportation risultano i più difficili da prevedere ($RMSE$ rispettivamente ≈ 10 e ≈ 6), mentre le serie rinnovabili presentano errori assoluti molto bassi (ad esempio $RMSE \approx 0,11$) con RMSE relativi generalmente prossimi a 1 per le componenti più variabili.

Serie	Energy				CO ₂			
	RMSE	RMSE relativo ³	MAE	MSFE	RMSE	RMSE relativo	MAE	MSFE
<i>Fossile_Industrial</i>	59,73	0,75	43,80	3567,39	5,47	0,89	4,42	29,99
<i>Fossile_Commercial</i>	36,29	0,23	28,82	1316,99	1,92	0,20	1,51	3,69
<i>Fossile_Residential</i>	76,04	0,23	59,84	5782,23	3,86	0,20	2,98	14,95
<i>Fossile_ElectricPower</i>	148,30	0,47	117,92	21992,02	10,45	0,46	7,98	109,17
<i>Fossile_Transportation</i>	53,16	0,59	41,62	2825,57	5,69	0,47	4,57	32,43
<i>Rinnovabile_Industrial</i>	7,27	0,82	5,66	52,80	0,46	1,05	0,36	0,22
<i>Rinnovabile_Commercial</i>	0,49	0,83	0,38	0,24	0,04	0,88	0,03	0,01
<i>Rinnovabile_Residential</i>	1,41	0,90	1,11	1,99	0,11	0,94	0,08	0,01
<i>Rinnovabile_ElectricPower</i>	9,53	0,85	7,73	90,76	0,12	0,63	0,09	0,01
<i>Rinnovabile_Transportation</i>	5,77	0,77	4,54	33,36	0,29	0,76	0,21	0,08

Tabella 5: Risultati VAR_k (6)

³ $RMSE_{relativo} = \frac{RMSE_{modello}}{Deviazione\ Standard_{serie}}$

3.2.2 IRF (Impulse Response Functions) di VAR

Dopo aver analizzato i risultati del modello VAR classico per i due sistemi separati di CO₂ ed Energy, si è stimato il modello VAR considerando congiuntamente i valori di energia consumata e le rispettive emissioni di CO₂ per condurre l'analisi delle Impulse Response Functions ([IRF](#)), con l'obiettivo di interpretare come uno shock dei consumi energetici, in ciascun settore e fonte energetica, si trasmetta nel tempo in variazioni delle emissioni di anidride carbonica (CO₂).

Operativamente le funzioni IRF sono state ottenute a partire da un VAR stimato sul sistema combinato $\mathbf{Y}^{Joint} = Energy; CO_2$ e per ottenere shock economici puri e non correlati è stata applicata la decomposizione ortogonale di Cholesky della matrice di varianza-covarianza degli errori, dove le variabili di consumo energetico sono state ordinate prima delle corrispondenti emissioni di CO₂, riflettendo l'ipotesi economica secondo cui sono i consumi di energia a determinare le emissioni di anidride carbonica e non viceversa. Le funzioni IRF sono state calcolate su un orizzonte temporale di 24 mesi e accompagnate da intervalli di confidenza al 95% ottenuti mediante una procedura bootstrap con 1000 repliche rappresentati dalle bande di confidenza colorate, mentre la linea nera mostra la risposta media stimata dal modello.

Dai risultati emerge un comportamento oscillatorio che riflette la natura ciclica delle dinamiche energetiche: l'analisi delle combinazioni esatte Figura 12, in cui ciascun settore risponde a uno shock nei propri consumi energetici, evidenzia risultati molto chiari nei settori appartenenti alle fonti fossili un aumento positivo nei consumi genera un aumento immediato nelle emissioni di CO₂, che risulta molto pronunciato nei primi mesi. La risposta iniziale è evidente nei settori Electric Power e Transportation, dove le emissioni di anidride carbonica mostrano picchi molto marcati subito dopo lo shock, seguiti da oscillazioni cicliche che riflettono i processi produttivi nei diversi mercati energetici. La situazione nel settore Residential e Commercial rimane permanente per molti mesi segnalando un effetto persistente per le emissioni di CO₂. Al contrario per i settori delle fonti energetiche rinnovabili la risposta delle emissioni di CO₂ a uno shock positivo nei consumi è molto più contenuta e di durata limitata, le oscillazioni si annullano rapidamente e spesso le bande di confidenza includono lo zero per quasi tutto l'orizzonte temporale, suggerendo un impatto non particolarmente significativo. L'intuizione economica generale è evidente e chiara, trattandosi di fonti rinnovabili, un aumento del consumo di energia non genera variazioni rilevanti nelle emissioni di anidride carbonica.

Ogni pannello della Figura 12 rappresenta una combinazione esatta delle funzioni IRF, ad esempio il pannello Fossile_Residential descrive la risposta delle emissioni di CO₂ del settore dei trasporti a uno shock nei consumi energetici fossili dello stesso settore:

$$\text{Energy_Fossile_Residential} \rightarrow \text{CO}_2\text{_Fossile_Residential}$$




Figura 12: Funzione IRF combinazioni esatte

Un ulteriore livello di analisi è fornita dalla rappresentazione completa per tutte le combinazioni di variabili in Figura 13, che ha permesso di esaminare gli effetti incrociati tra settori e fonti differenti, in questo caso, ciascun pannello della figura rappresenta la risposta delle emissioni di CO₂ di un settore (in colonna) a uno shock nei consumi energetici di un altro settore (nelle righe). L'analisi globale evidenzia una chiara struttura a blocchi: gli shock nei consumi energetici fossili generano risposte più rilevanti nelle emissioni dei settori fossili mentre gli shock nei consumi energetici rinnovabili producono risposte trascurabili sia sulle emissioni rinnovabili sia su quelle fossili. Invece, gli effetti incrociati tra fossili verso i settori rinnovabili e viceversa risultano deboli o praticamente nulli: queste evidenze osservate dai pannelli grafici suggerisce una limitata dipendenza delle emissioni tra settori caratterizzati da fonti energetiche differenti e rafforza l'interpretazione affermata precedentemente, dove le dinamiche delle emissioni di CO₂ sono prevalentemente guidate dai consumi di energia fossile.




Figura 13: Funzione IRF tutte le combinazioni

Nel complesso, l'analisi grafica delle Impulse Response Functions conferma in modo dinamico il legame strutturale tra energia consumata ed emissioni di anidride carbonica, dove da un lato gli shock dei consumi di energia fossile costituiscono le principali fonti di fluttuazioni di CO₂ nei diversi settori economici, mentre dall'altro lato l'energia rinnovabile produce effetti trascurabili come ci si poteva aspettare. Queste evidenze osservate permettono di interpretare più chiaramente le relazioni intercettate dal modello VAR_k (6) e successivamente svolgere un confronto approfondito con i modelli penalizzati HVAR.

3.2.3 Regularizzazione HVAR

Come anticipato nella parte teorica del primo capitolo, per la stima dei modelli VAR penalizzati è stato utilizzato il framework HVAR implementato nel pacchetto BigVAR il quale consente di combinare penalizzazioni strutturate HLAG con una procedura di selezione del parametro di regolarizzazione λ basata su rolling cross-validation one-step-ahead. Come effettuato nel modello VAR classico, sono stati considerati separatamente i due sistemi multivariati relativi alle emissioni di CO₂ e ai consumi energetici, a partire dalle matrici dei dati $\mathbf{Y}^{CO_2}$ e $\mathbf{Y}^{Energy}$ sulle quali si sono definite le stesse suddivisioni temporali:

- Training ($1:T_1$) $\approx 70\%$ del campione utilizzato per stimare le prime specificazioni del modello e inizializzare le previsioni ricorsive;
- Rolling cross-validation ($T_1 + 1:T_2$) $\approx 20\%$ del campione utilizzata da BigVAR per selezionare il valore ottimale di λ che minimizza l'errore di previsione one-step-ahead;
- Test out-of-sample ($T_2 + 1:T$) $\approx 10\%$ del campione per valutare le performance finali.

Per tutte le strutture utilizzate da HVAR i modelli sono stati specificati in R nel seguente modo:

```
model <- constructModel(  
  Y      = Y_mat,  
  p      = 12,  
  struct = "HLAGC",  
  T1     = T1,  
  T2     = T2,  
  gran   = c(400, 7),  
  cv     = "Rolling",  
  h      = h_forecast,  
  IC     = FALSE,  
  verbose = TRUE,  
  model.controls = list(  
    intercept = TRUE,  
    standardize = TRUE))
```

Figura 14: Costruzione dei modelli HVAR

Nello specifico, ogni voce del codice riportato in Figura 14, viene utilizzato per costruire i modelli in maniera ottimale: sono state prese le matrici di riferimento sia per $\mathbf{Y}^{CO_2}$ che per $\mathbf{Y}^{Energy}$, il massimo ordine di lag è stato fissato a $p = 12$ in linea con la frequenza mensile dei dati storici, $struct \in \{HLAGC, HLAGOO, HLAGOLEM\}$ si riferisce alla struttura gerarchica della penalizzazione in ordine Componentwise, Own/Other e Elementwise, $gran = c(400, 7)$ indica che BigVAR esplora 7 valori di λ distribuiti lungo una griglia logaritmica ed il primo

numero (400) è la profondità della griglia ovvero il rapporto tra il valore massimo e il valore minimo del parametro di penalizzazione, $cv = \text{"Rolling"}$ fa riferimento alla rolling cross-validation one-step-ahead con orizzonte di previsione $h_{forecast} = 1$, mentre l'opzione imposta $standardize = TRUE$ fa sì che le serie storiche siano internamente standardizzate prima di applicare la penalizzazione garantendo comparabilità tra le variabili di diversa scala (come energia consumata espressa in Trillion BTU ed emissioni di CO₂ espresse in milioni di tonnellate metriche), è stata inclusa l'intercetta ($intercept = TRUE$) ma non viene penalizzata. Per ogni specificazione che è stata effettuata la funzione `cv.BigVAR()` seleziona in modo automatico il valore ottimale di λ sul periodo $1:T_2$, successivamente il valore ottimale λ utilizzato per la valutazione delle performance out-of-sample tramite rolling-expanding sul periodo $T_2 + 1:T$. Le performance previsive sono state calcolate sulle previsioni one-step-ahead e la struttura di sparsità ottenuta è stata analizzata attraverso gli sparsity plot forniti da BigVAR, che rappresentano la distribuzione dei coefficienti non nulli per ciascuna equazione e lag.

Risultati per il sistema ENERGY

I risultati ottenuti per il sistema dell'energia consumata mostrano che la penalizzazione porta ad un elevato grado di sparsità, con una diversa intensità in base alla struttura utilizzata:

- HLAGC $\approx 67\%$ attivi (struttura più densa);
- HLAGOO $\approx 54\%$ coefficienti attivi;
- HLAGLEM $\approx 17\%$ coefficienti attivi (massima parsimonia).

Nella Figura 15 degli sparsity pattern per le tre strutture di penalizzazione, emerge che i settori fossili presentano forti dipendenze ai primi lag i quali riflettono la persistenza dei consumi energetici tradizionali (presenza di stagionalità residua data dal calendario e legata a cicli di riscaldamento/raffreddamento). I settori rinnovabili invece mostrano pochi legami dinamici sia tra di loro sia verso i settori fossili: si osserva una dinamica lenta e regolata guidata dall'utilizzo intermittente di alcune tecnologie rinnovabili che non sono in grado di raggiungere i livelli delle tecnologie fossili. Mentre gli effetti incrociati tra fonti fossili e rinnovabili sono abbastanza limitati e, quando presenti, sono concentrati entro 1–2 mesi questo può significare che la domanda energetica complessiva si adatta molto rapidamente ai diversi shock ma la riallocazione tra fonti fossili e rinnovabili rimane limitata internamente.




Figura 15: Sparsity Pattern tre strutture di penalizzazione

Modello	Out-of-Sample Loss
Componentwise	26.300
Own/Other	31.700
Elementwise	27.400
Random Walk	153.000
Conditional Mean	246.000

Tabella 6: Risultati errore Out-of-Sample

Nella Tabella 6 sono riportate le perdite fuori campione aggregate (Out-of-Sample Loss) per i tre modelli HVAR e per i benchmark non strutturati: si osserva che tutti i modelli HVAR migliorano l'errore previsivo del 70–85% rispetto ai benchmark non strutturati e a livello complessivo, tra le varie strutture penalizzate, il modello Componentwise risulta essere il migliore dal punto di vista predittivo, il modello Elementwise risulta essere il più parsimonioso mentre il modello Own/Other si colloca in una posizione intermedia e mostra prestazioni previsive peggiori rispetto alle altre due strutture in particolare nei settori fossili più volatili (Electric Power e Transportation).

	<i>Componentwise</i>				<i>Own/Other</i>				<i>Elementwise</i>			
Serie Energy	RMSE	RMSE relativo	MAE	MSFE	RMSE	RMSE relativo	MAE	MSFE	RMSE	RMSE relativo	MAE	MSFE
<i>Fossile_Industrial</i>	64,45	0,81	44,97	4154,15	70,11	0,88	50,25	4915,57	66,19	0,83	46,70	4380,76
<i>Fossile_Commercial</i>	31,56	0,20	23,37	995,96	33,99	0,21	25,01	1155,19	32,69	0,20	23,64	1068,63
<i>Fossile_Residential</i>	61,92	0,19	45,58	3833,56	66,77	0,20	51,01	4457,63	62,63	0,19	45,69	3922,46
<i>Fossile_ElectricPower</i>	120,28	0,39	93,57	14466,72	131,34	0,42	101,49	17249,74	122,44	0,39	95,16	14991,68
<i>Fossile_Transportation</i>	51,27	0,57	37,58	2628,86	61,15	0,68	46,95	3739,51	53,54	0,60	40,73	2867,02
<i>Rinnovabile_Industrial</i>	8,44	0,96	6,54	71,19	8,78	1,00	6,68	77,12	8,49	0,96	6,56	72,09
<i>Rinnovabile_Commercial</i>	0,59	0,99	0,44	0,35	0,59	0,99	0,44	0,35	0,59	0,99	0,44	0,35
<i>Rinnovabile_Residential</i>	1,57	0,99	1,27	2,46	1,57	0,99	1,27	2,47	1,55	0,98	1,25	2,39
<i>Rinnovabile_ElectricPower</i>	9,30	0,83	6,91	86,46	9,26	0,82	7,39	85,69	9,27	0,83	7,06	85,87
<i>Rinnovabile_Transportation</i>	7,22	0,96	5,63	52,08	7,44	0,99	5,78	55,39	7,15	0,95	5,58	51,14


Tabella 7: Risultati HVAR

Risultati per il sistema CO₂


Per il sistema delle emissioni di anidride carbonica i modelli HVAR mostrano un comportamento simile a quello osservato per i consumi energetici ma con un livello di variabilità complessivo più contenuto e con livello di sparsità pari a:

- HLAGC frazione di coefficienti attivi $\approx 64\%$;
- HLAGOO coefficienti attivi $\approx 50\%$;
- HLAGLEM coefficienti attivi $\approx 19\%$, modello più parsimonioso.

Sparsity Pattern: CO₂-Componentwise



Sparsity Pattern: CO₂-Own/Other



Sparsity Pattern: CO₂-Elementwise




Figura 16: Sparsity Pattern tre strutture di penalizzazione

La lettura delle percentuali di sparsità risulta coerente con gli sparsity pattern della Figura 16: le fonti fossili mostrano una forte componente dinamica caratterizzata da diversi coefficienti attivi e da relazioni persistenti tra i vari settori mentre le fonti rinnovabili presentano una struttura quasi completamente piatta, evidenziando una struttura emissiva altamente segmentata dove le componenti rinnovabili non reagiscono agli shock degli altri settori questo accade perché le fonti fossili hanno emissioni di anidride carbonica più significative rispetto alle fonti rinnovabili che per natura non producono emissioni di anidride carbonica.

Modello	Out-of-Sample Loss
Componentwise	151
Own/Other	161
Elementwise	152
Random Walk	889
Conditional Mean	1160

Tabella 8: Risultati errore Out-of-Sample

Il confronto tra le strutture di penalizzazione calcolate mostra che la complessità del modello varia sensibilmente in base al numero di coefficienti attivi e non attivi; in questo sistema CO₂ la struttura Componentwise è la più performante, seguita dalla struttura Elementwise che garantisce un'elevata parsimonia mantenendo performance praticamente identiche mentre la struttura Own/Other è leggermente meno efficace, questo perché la distinzione rigida tra coefficienti “own” e “other” non cattura perfettamente le interdipendenze tra i settori fossili e rinnovabili. Come nel sistema Energy, tutti i modelli HVAR migliorano l'errore fuori campione di oltre il 70% rispetto al Random Walk e di oltre l'80% rispetto alla media condizionale, confermando la presenza di una componente autoregressiva significativa nel sistema emissivo e la capacità delle penalizzazioni strutturate di gestire efficacemente modelli ad alta dimensionalità.

	<i>Componentwise</i>				<i>Own/Other</i>				<i>Elementwise</i>			
Serie CO₂	RMSE	RMSE relativo	MAE	MSFE	RMSE	RMSE relativo	MAE	MSFE	RMSE	RMSE relativo	MAE	MSFE
<i>Fossile_Industrial</i>	5,25	0,86	4,12	27,54	5,58	0,92	4,36	31,17	5,40	0,88	4,22	29,12
<i>Fossile_Commercial</i>	1,70	0,18	1,29	2,90	1,69	0,18	1,24	2,85	1,70	0,18	1,25	2,91
<i>Fossile_Residential</i>	3,15	0,16	2,35	9,90	3,29	0,17	2,45	10,80	3,15	0,16	2,32	9,91
<i>Fossile_ElectricPower</i>	8,95	0,40	7,17	80,07	8,99	0,40	7,26	80,74	8,89	0,39	7,22	78,99
<i>Fossile_Transportation</i>	5,51	0,45	4,21	30,40	5,89	0,48	4,58	34,64	5,54	0,46	4,26	30,72
<i>Rinnovabile_Industrial</i>	0,43	0,98	0,36	0,19	0,44	0,99	0,37	0,19	0,45	1,01	0,38	0,20
<i>Rinnovabile_Commercial</i>	0,05	0,99	0,04	0,01	0,05	0,99	0,04	0,00	0,05	0,99	0,04	0,00
<i>Rinnovabile_Residential</i>	0,11	0,99	0,08	0,01	0,11	0,99	0,08	0,01	0,11	0,99	0,08	0,01
<i>Rinnovabile_ElectricPower</i>	0,18	0,99	0,15	0,03	0,18	0,99	0,15	0,03	0,18	0,99	0,15	0,03
<i>Rinnovabile_Transportation</i>	0,37	0,97	0,28	0,14	0,37	0,99	0,28	0,14	0,36	0,96	0,28	0,13

Tabella 9: Risultati HVAR

Considerando entrambi i sistemi che sono stati analizzati, emerge una cornice estremamente coerente e chiara: i modelli HVAR riescono ad isolare in modo molto efficace la diversa natura delle serie per fonti fossili e rinnovabili e le diverse penalizzazioni individuano automaticamente che i settori fossili richiedono molti più coefficienti attivi perché presentano una maggiore richiesta di utilizzo con una dinamica persistente e influenzata da shock economici, climatici o di domanda energetica. Mentre le fonti rinnovabili in questo contesto, sia di consumo sia di emissioni di CO₂, risultano fortemente penalizzate poiché la loro variabilità mensile è molto ridotta, l'utilizzo è nettamente inferiore rispetto alle fonti fossili di conseguenza i loro coefficienti vengono ridotti a zero dal sistema multivariato.

In questo contesto i modelli penalizzati non “sfavoriscono” le fonti rinnovabili ma riflettono il fatto che le loro serie storiche non contengono informazione dinamiche, né relazioni significative con gli altri settori in comparazione con le fonti fossili.

3.2.4 IRF (Impulse Response Functions) di HVAR

Per il modello HVAR stimato mediante l'approccio penalizzato di BigVAR, le funzioni di risposta agli impulsi (IRF) sono state calcolate in R a partire dai coefficienti stimati tramite BigVAR si sono ottenute le funzioni IRF puntuali e successivamente si sono costruite le bande di confidenza tramite procedura bootstrap sui residui. L'intera implementazione in R risulta essere coerente con la rappresentazione del modello VAR e con la costruzione delle IRF tramite la matrice companion e decomposizione di Cholesky, secondo l'impostazione di Lütkepohl, H. (2005) "New Introduction to Multiple Time Series Analysis".

Il punto di partenza è stato quello di stimare esclusivamente il modello HVAR con struttura HLAGC (componentwise), che risulta essere il modello con una struttura di sparsità dei coefficienti più densa tra quelle considerate, è stato fissato l'ordine dei ritardi a $p = 12$ e la scelta del parametro di penalizzazione λ è stata effettuata tramite cross-validation con schema rolling (cv="Rolling"). Una volta selezionato il λ ottimale, BigVAR ha restituito la matrice dei coefficienti $\hat{\Phi}$ tuttavia non fornisce direttamente la matrice dei regressori laggiati utilizzata nella stima e quindi è stato necessario ricostruire esplicitamente la struttura $\text{VAR}_k(p)$ equivalente. Per questo motivo si è utilizzata una funzione ausiliaria per costruire il vettore dei regressori laggiati, per ogni istante temporale t , $\mathbf{Z}_t = (Y_{t-1}^\top, \dots, Y_{t-p}^\top)^\top$ e questo ha reso possibile calcolare i valori stimati e i residui in modo coerente con il modello penalizzato:

- Valori stimati $\hat{\mathbf{Y}}_t = \hat{\mathbf{c}} + \hat{\Phi}\mathbf{Z}_t$ dove $\hat{\mathbf{c}}$ rappresenta il vettore delle intercette e $\hat{\Phi}$ rappresenta la matrice dei coefficienti associati ai ritardi;
- I residui $\hat{\mathbf{e}}_t = \mathbf{Y}_t - \hat{\mathbf{Y}}_t$, la matrice di covarianza dei residui è $\hat{\Sigma}_U = \text{cov}(\hat{\mathbf{E}})$ che ha permesso di calcolare gli shock strutturali ortogonalizzati.

È stata sfruttata l'impostazione di Lütkepohl, H. (2005), ed i coefficienti $\hat{\Phi}$ sono stati trasformati nella matrice companion $\mathbf{A}$ (che consente di riscrivere il sistema $\text{VAR}_k(p)$ in forma $\text{VAR}_k(1)$), inoltre è stata costruita una matrice di selezione $\mathbf{J}$ (che permette di estrarre dal vettore di stato le variabili osservate). Si è proceduto poi all'ortogonalizzazione della covarianza residua tramite decomposizione di Cholesky $\hat{\Sigma}_U = \mathbf{P}\mathbf{P}^\top$ dove $\mathbf{P}$ rappresenta la matrice degli shock strutturali ortogonali. La risposta per l'orizzonte h è stata costruita come: $\Theta_h = \mathbf{J}\mathbf{A}^{h-1}\mathbf{J}^\top\mathbf{P}$ per $h = 1, \dots, H$ con $H = 24$ ed infine si è ottenuto l'array delle funzioni puntuali $\widehat{IRF}[h, i, j]$ che misura l'effetto di uno shock strutturale nella variabile j sulla variabile i all'orizzonte h .

Successivamente, per stimare l'incertezza associata a queste risposte, si è implementata una procedura bootstrap sui residui che combina un moving block bootstrap con un wild bootstrap: nel moving block bootstrap multivariato ogni blocco è stato estratto simultaneamente su tutte le variabili in modo da preservare la struttura dell'autocorrelazione temporale a cui è stato sovrapposto un meccanismo wild dove ciascun blocco estratto è stato moltiplicato per un fattore casuale $w \in \{-1, +1\}$ con uguale probabilità, si sono così ottenuti i residui bootstrap e_t^* , mentre la componente deterministica del modello è stata mantenuta fissa e per ogni replica si è costruita:

$$Y_t^* = \hat{Y}_t + e_t^* \quad (3.1)$$

Per ciascuna replica bootstrap $b = 1, \dots, B$ (con $B = 1000$) si è ristimato il modello con BigVAR.fit con la stessa struttura HLAGC e lo stesso λ ottimale che è stato selezionato precedentemente nel campione originale. In questo modo dalla stima bootstrap si sono estratte nuovamente l'intercetta e i coefficienti dei lag, si sono ricostruiti i regressori, si è calcolata $\hat{\Sigma}_U^{(b)}$ ed infine si sono calcolate le IRF con la stessa procedura companion + Cholesky: si è ripetuto il ciclo su tutte le repliche e si è ottenuto finalmente l'array $IRF_{boot}[h, i, j, b]$.




Figura 17: Funzione IRF combinazioni esatte

Ogni pannello della Figura 17 rappresenta una combinazione esatta delle funzioni IRF, ad esempio il pannello Fossile_ElectricPower descrive la risposta delle emissioni di CO₂ del settore dei trasporti a uno shock nei consumi energetici fossili dello stesso settore:

$$\text{Energy_Fossile_ElectricPower} \rightarrow \text{CO}_2_ \text{Fossile_ElectricPower}$$

Nella Figura 17 si evidenzia che gli andamenti oscillatori possono riflettere meccanismi di aggiustamento nel mix energetico, inclusi effetti di sostituzione tra fonti con una significatività che tende a ridursi oltre i primi mesi.




Figura 18: Funzione IRF tutte le combinazioni

In questo caso nella Figura 18, ciascun pannello rappresenta la risposta delle emissioni di CO₂ di un settore (in colonna) a uno shock nei consumi energetici di un altro settore (nelle righe). Nel complesso le funzioni IRF confermano l'asimmetria già osservata tra fonti fossili e rinnovabili: le prime fonti energetiche risultano fortemente rilevanti nel determinare le diverse dinamiche di breve periodo delle emissioni di anidride carbonica, mentre le seconde fonti energetiche mostrano effetti deboli, che possono essere considerati transitori e non significativi.

3.3 Applicazione modelli VARX e regolarizzazione VARX-L

In questo sottocapitolo si descrive l'applicazione dei modelli $\text{VARX}_{k,m}(p,s)$ con variabili esogene e le loro estensioni regolarizzate VARX-L, i quali permettono di superare i limiti dei modelli VAR classici che considerano esclusivamente le variabili endogene senza considerare l'influenza di fattori macroeconomici esterni. L'introduzione di variabili esogene all'interno del sistema autoregressivo permette di passare da un modello VAR ad un sistema VARX e questo risulta essere utile nel contesto che è stato analizzato nella tesi, poiché le emissioni di CO_2 e i consumi energetici sono fortemente influenzati dal ciclo economico, dall'andamento della produzione industriale, dal mercato del lavoro e dalla dinamica demografica degli Stati Uniti.

3.3.1 Procedura di stima del modello VARX

La procedura di stima del modello $\text{VARX}_{k,m}(p,s)$ è stata sviluppata a partire dalla costruzione delle variabili esogene di natura macroeconomica, variabili pre-processate precedentemente che rappresentano serie storiche cicliche dell'attività economica statunitense. Anche in questo caso la procedura di stima adottata segue la seguente suddivisione temporale:

- Training ($1:T_1$) $\approx 70\%$ del campione utilizzato per stimare i modelli iniziali;
- Rolling cross-validation ($T_1 + 1:T_2$) $\approx 20\%$ del campione utilizzato per la validazione dinamica del modello;
- Test out-of-sample ($T_2 + 1:T$) $\approx 10\%$ del campione che è stato utilizzato per la valutazione finale delle performance previsive, con procedura rolling-expanding window out-of-sample descritta precedentemente.

La stima del modello $\text{VARX}_{k,m}(p,s)$ è stata effettuata fissando un numero di ritardi delle variabili endogene pari a $p = 6$, coerente con il modello VAR, mentre per le variabili esogene non sono stati fissati ritardi ed è stato impostato $s = 0$ inserendo così i regressori in forma contemporanea per contenere il numero di parametri da stimare che altrimenti tenderebbe progressivamente ad aumentare:

Parte endogena: $k^2 p = 10^2 \times 6 = 600$ coefficienti;

Parte esogena: $k \times m \times (s + 1) = 10 \times 5 \times 1 = 50$ coefficienti.

	<i>Energy</i>				<i>CO₂</i>			
Serie	RMSE	RMSE relativo	MAE	MSFE	RMSE	RMSE relativo	MAE	MSFE
<i>Fossile_Industrial</i>	55,85	0,70	43,65	3118,86	5,41	0,88	4,44	29,31
<i>Fossile_Commercial</i>	37,30	0,23	29,89	1391,28	1,98	0,21	1,54	3,92
<i>Fossile_Residential</i>	78,26	0,23	63,29	6124,90	4,03	0,21	3,15	16,21
<i>Fossile_ElectricPower</i>	146,61	0,47	116,74	21495,24	10,43	0,46	8,18	108,81
<i>Fossile_Transportation</i>	54,46	0,60	42,25	2966,02	5,66	0,46	4,64	32,00
<i>Rinnovabile_Industrial</i>	8,18	0,93	6,35	67,00	0,48	1,09	0,38	0,24
<i>Rinnovabile_Commercial</i>	0,49	0,83	0,38	0,24	0,05	0,90	0,03	0,01
<i>Rinnovabile_Residential</i>	1,50	0,95	1,19	2,26	0,11	0,97	0,08	0,01
<i>Rinnovabile_ElectricPower</i>	9,69	0,86	7,94	93,90	0,12	0,65	0,09	0,01
<i>Rinnovabile_Transportation</i>	5,58	0,74	4,46	31,16	0,28	0,74	0,21	0,08

Tabella 10: Risultati VARX_{k,m}(6,0)

Per il sistema delle emissioni di CO₂ i risultati riportati nella Tabella 10 mostrano una buona capacità predittiva del modello VARX, in particolare per le componenti di fonte rinnovabile gli errori medi sono contenuti mentre per le serie storiche legate alle fonti fossili presentano errori più elevati e variabili. Questo pattern tra fonti fossili e rinnovabili si presenta anche per il sistema riguardante l'energia consumata dove il modello VARX evidenzia valori di RMSE relativo generalmente inferiori all'unità e anche in questo caso le componenti rinnovabili risultano meglio previste rispetto a quelle fossili perché presentano meno volatilità.

Nel complesso l'inclusione delle variabili esogene, rispetto al modello VAR stimato precedentemente, consente di catturare in modo efficace l'influenza del ciclo economico sulle serie endogene; tuttavia, l'elevato numero di parametri che devono essere stimati cresce rapidamente con il numero di variabili e dei ritardi, per questo motivo nel sottocapitolo successivo si è introdotta la versione regolarizzata VARX-L.

3.3.2 Regularizzazione VARX-L

Per affrontare i problemi ampiamente descritti di sovra-parametrizzazione dei modelli VARX in questa sezione è stata introdotta la versione regolarizzata VARX-L: questo approccio implementato nel framework BigVAR permette di combinare la struttura dei modelli VARX con tecniche di penalizzazione di tipo Lasso in cui è stato così possibile estendere la struttura del modello includendo una dinamica esogena più profonda impostando il numero di ritardi. Operativamente sono state aggregate in un'unica matrice le variabili endogene (che rappresentano le serie da modellare e prevedere) e le variabili esogene macroeconomiche (che entrano nel modello come regressori esterni soggetti anch'essi a regolarizzazione) separatamente per i sistemi $\mathbf{Y}^{CO_2}$ e $\mathbf{Y}^{Energy}$.

```
VARX_spec <- list(
  k      = k,
  s      = 6,
  contemp = FALSE)

# Costruisco il modello VARX-L
model_EN_VARXL <- constructModel(
  Y      = Y_VARX,
  p      = p_max,
  struct = "Lag",
  gran   = c(50, 10),
  VARX   = VARX_spec,
  T1     = T1_varx,
  T2     = T2_varx,
  h      = 1,
  cv     = "Rolling",
  IC     = FALSE,
  verbose = TRUE,
  model.controls = list(
    intercept = TRUE,
    standardize = TRUE))
```

Figura 19: Costruzione del modello VARX-L

Per questo tipo di regolarizzazione VARX-L è stata effettuata imponendo solamente una struttura di penalizzazione di tipo *Lag* sui coefficienti associati ai ritardi che consente di selezionare automaticamente le relazioni dinamiche significative tra le variabili del sistema. Nello specifico la struttura del codice riportato in Figura 19, viene utilizzato per costruire i modelli in maniera ottimale: matrici di riferimento sia per $\mathbf{Y}^{CO_2}$ che per $\mathbf{Y}^{Energy}$ con le 5 variabili esogene incorporate (Prodotto Interno Lordo USA, Indice di produzione industriale USA, Popolazione USA, Fornitura nuove case USA, Livello di occupazione), la specificazione `struct = Lag` si riferisce alla struttura gerarchica della penalizzazione, `gran = c(50, 10)` indica che

BigVAR esplora 10 valori di λ distribuiti lungo una griglia logaritmica ed il primo numero (50) è la profondità della griglia ovvero il rapporto tra il valore massimo e il valore minimo del parametro di penalizzazione, $cv = \text{"Rolling"}$ fa riferimento alla rolling cross-validation one-step-ahead con orizzonte di previsione pari a $h_{forecast} = 1$, mentre l'opzione impostata $standardize = TRUE$ fa sì che le serie storiche siano internamente standardizzate prima di applicare la penalizzazione garantendo comparabilità tra le variabili di diversa scala, è stata inclusa l'intercetta ($intercept = TRUE$) ma non viene penalizzata. Per ogni specificazione che è stata effettuata la funzione `VARX_spec` seleziona in modo automatico il valore ottimale del parametro di penalizzazione, le performance previsive sono state calcolate tramite le principali metriche di errore (RMSE, MAE e MSFE) sulle previsioni one-step-ahead.

Serie	Energy				CO ₂			
	RMSE	RMSE relativo	MAE	MSFE	RMSE	RMSE relativo	MAE	MSFE
<i>Fossile_Industrial</i>	63,97	0,81	46,43	4092,46	5,12	0,84	3,94	26,19
<i>Fossile_Commercial</i>	30,69	0,19	20,67	941,97	1,67	0,17	1,18	2,80
<i>Fossile_Residential</i>	60,72	0,18	41,19	3687,58	3,09	0,16	2,25	9,58
<i>Fossile_ElectricPower</i>	118,76	0,38	97,18	14103,77	8,90	0,40	7,24	79,26
<i>Fossile_Transportation</i>	48,40	0,54	37,47	2341,93	5,36	0,44	4,34	28,82
<i>Rinnovabile_Industrial</i>	7,51	0,85	5,55	56,48	0,37	0,85	0,29	0,14
<i>Rinnovabile_Commercial</i>	0,48	0,82	0,35	0,24	0,04	0,83	0,02	0,01
<i>Rinnovabile_Residential</i>	1,06	0,66	0,84	1,12	0,08	0,78	0,07	0,07
<i>Rinnovabile_ElectricPower</i>	8,00	0,71	6,11	64,07	0,11	0,64	0,09	0,01
<i>Rinnovabile_Transportation</i>	6,46	0,86	5,09	41,82	0,33	0,87	0,25	0,11

Tabella 11: Risultati VARX-L

I risultati riportati in Tabella 11 mostrano che l'introduzione della regolarizzazione consente di migliorare le performance previsive rispetto al modello non penalizzato, è possibile osservare già in questa fase dell'analisi che l'inclusione delle variabili esogene combinata con la penalizzazione Lasso contribuisce in particolare a migliorare la qualità delle previsioni per le fonti rinnovabili, facendo intendere che la dinamica delle fonti rinnovabili sia caratterizzata da una dipendenza macroeconomica più marcata.

Capitolo 4: Risultati e discussione

Nel quarto ed ultimo capitolo del presente lavoro di tesi sono stati comparati i risultati ottenuti dall'applicazione dei diversi modelli presentati sia dal punto di vista grafico sia dal punto di vista di accuratezza previsiva attraverso il Mean Squared Forecast Error – Errore quadratico medio di previsione (MSFE). Successivamente sono state riportate le previsioni future dei consumi energetici e delle emissioni di anidride carbonica (CO₂) ottenute applicando il modello che ha mostrato le migliori performance out-of-sample.

4.1 Confronto modelli e implicazioni pratiche

I risultati principali presentati nei capitoli precedenti della modellazione BigVAR hanno portato a delle conclusioni chiare ed evidenti: i modelli non regolarizzati VAR e VARX producono dei risultati soddisfacenti nonostante l'elevata dimensionalità dei parametri ma un aspetto cruciale risulta essere l'efficacia della penalizzazione nel gestire l'elevata dimensionalità dei sistemi, composto dalle variabili endogene di energia consumata e di emissioni CO₂ e dalle variabili esogene macroeconomiche. Il confronto tra l'approccio regolarizzato HVAR e VARX-L evidenzia una differenza sostanziale nella gestione dei coefficienti poiché il modello HVAR tende ad azzerare interamente i contributi delle fonti meno volatili in questo caso le fonti rinnovabili, mentre il modello VARX-L con l'aggiunta delle variabili esogene macroeconomiche mostra una maggiore capacità di preservare l'informazione rilevante anche per fonti poco volatili. Dai grafici mostrati (Figure 20-31) si è osservato il confronto tra l'andamento reale delle serie storiche osservate e le traiettorie generate dai diversi modelli applicati durante il periodo di test: la serie storica (traiettoria raffigurata in nero) identifica i valori reali osservati nel periodo di test, le restanti traiettorie rappresentano le previsioni out-of-sample ad un passo (1-step-ahead forecast) prodotte dai modelli che sono stati applicati ai dati delle serie storiche.

Per riassumere, l'analisi quantitativa e grafica evidenziano come la modellazione VARX-L sia quella che garantisce la migliore accuratezza previsiva out-of-sample e nel contesto del lavoro di tesi sottolinea l'importanza di considerare informazioni esogene, per creare una struttura dinamica più ricca, questo suggerisce che la sola componente endogena non è in grado di spiegare in certe fonti energetiche e settori economici.

Grafici sistema Energy

Serie Storica
 VAR
 HVAR
 VARX
 VARX-L




Figura 20: Rinnovabile_Residential




Figura 21: Fossile_Residential




Figura 22: Rinnovabile_Industrial




Figura 23: Fossile_Industrial




Figura 24: Rinnovabile_ElectricPower




Figura 25: Fossile_ElectricPower

Grafici sistema CO₂





Figura 26: Rinnovabile_Commercial




Figura 27: Fossile_Commercial



Figura 28: Rinnovabile_Transportation




Figura 29: Fossile_Transportation




Figura 30: Rinnovabile_ElectricPower




Figura 31: Fossile_ElectricPower

Nei sistemi multivariati la metrica di confronto utilizzata è il valore di MSFE (Mean Squared Forecasting Error) che risulta molto utile quando bisogna confrontare modelli penalizzati da modelli non penalizzati, si è osservato il valore minimo di MSFE per ogni sistema Energy e CO₂.

Serie Energy	MSFE VAR	MSFE HVAR	MSFE VARX	MSFE VARX-L	MSFE minore
<i>Fossile_Industrial</i>	3567,39	4154,15	3118,86	4092,46	VARX
<i>Fossile_Commercial</i>	1316,99	995,96	1391,28	941,97	VARX-L
<i>Fossile_Residential</i>	5782,23	3833,56	6124,90	3687,58	VARX-L
<i>Fossile_ElectricPower</i>	21992,02	14466,72	21495,24	14103,77	VARX-L
<i>Fossile_Transportation</i>	2825,57	2628,86	2966,02	2341,93	VARX-L
<i>Rinnovabile_Industrial</i>	52,80	71,19	67,00	56,48	VAR
<i>Rinnovabile_Commercial</i>	0,24	0,35	0,24	0,24	VARX-L
<i>Rinnovabile_Residential</i>	1,99	2,46	2,26	1,12	VARX-L
<i>Rinnovabile_ElectricPower</i>	90,76	86,46	93,90	64,07	VARX-L
<i>Rinnovabile_Transportation</i>	33,36	52,08	31,16	41,82	VARX

Tabella 12: Risultati modelli sistema Energy

Serie CO₂	MSFE VAR	MSFE HVAR	MSFE VARX	MSFE VARX-L	MSFE minore
<i>Fossile_Industrial</i>	29,99	27,54	29,31	26,19	VARX-L
<i>Fossile_Commercial</i>	3,69	2,90	3,92	2,80	VARX-L
<i>Fossile_Residential</i>	14,95	9,90	16,21	9,58	VARX-L
<i>Fossile_ElectricPower</i>	109,17	80,07	108,81	79,26	VARX-L
<i>Fossile_Transportation</i>	32,43	30,40	32,00	28,82	VARX-L
<i>Rinnovabile_Industrial</i>	0,22	0,19	0,24	0,14	VARX-L
<i>Rinnovabile_Commercial</i>	0,01	0,01	0,01	0,01	VARX-L
<i>Rinnovabile_Residential</i>	0,01	0,01	0,01	0,01	VARX-L
<i>Rinnovabile_ElectricPower</i>	0,01	0,03	0,01	0,01	VAR-L
<i>Rinnovabile_Transportation</i>	0,08	0,14	0,08	0,11	VARX

Tabella 13: Risultati modelli sistema CO₂

4.2 Previsioni dei consumi energetici ed emissioni di CO₂

Dalle conclusioni che sono state tratte nella fase precedente di valutazione previsiva, il modello con le migliori performance in termini di valore minimo di MSFE è risultato essere il modello VARX penalizzato con struttura VARX-L per la maggior parte delle serie storiche quindi, per questo motivo, si è voluto utilizzare tale regolarizzazione per l'elaborazione delle previsioni future della componente ciclica dei consumi energetici e delle emissioni di CO₂. L'analisi previsiva è stata condotta esclusivamente sulla componente ciclica delle serie storiche, escludendo la ricostruzione di trend e della stagionalità, poiché l'obiettivo è stato quello di analizzare l'evoluzione di medio periodo e l'incertezza ad esse associata. Le fasi dell'algoritmo esposte in [Appendice C](#) descrive la ricostruzione delle serie storiche originali, mentre nel seguente lavoro di tesi ci si è concentrati alla sola componente ciclica delle serie storiche.

Decomposizione e modellazione delle variabili esogene

La procedura di forecasting unita all'implementazione dell'algoritmo di bootstrap si è articolata in più fasi, l'orizzonte previsivo che è stato considerato è stato pari a 60 mesi ovvero 5 anni coprendo l'intervallo temporale 2025-2030. Come punto di partenza dell'algoritmo sono le serie storiche osservate sottoposte alla scomposizione già descritta nel Capitolo 2: in particolare l'applicazione di TRAMO-SEATS ha permesso di rimuovere la stagionalità ottenendo serie destagionalizzate depurate da fluttuazioni ricorrenti, mentre il filtro HPJ ha permesso di separare la componente ciclica dal trend di lungo periodo (residui indicati con $\hat{\varepsilon}_t$); queste procedure hanno permesso di ottenere l'andamento del ciclo economico che rappresenta l'unica componente utilizzata nelle fasi successive di previsione. Una volta isolata la componente ciclica delle variabili endogene, si sono trattate le variabili esogene i cui valori futuri sono attualmente ignoti quindi si è utilizzato un approccio simulativo, per ciascuna variabile esogena è stato stimato un modello SARIMA necessario per ottenere la previsione puntuale delle traiettorie future e anche per estrarre i residui associati (indicati con $\hat{\eta}_t$) a scenari stocastici futuri nella fase di bootstrap. È fondamentale sottolineare che la dinamica del ciclo economico viene descritta in funzione dei propri ritardi temporali e dei ritardi temporali delle variabili esogene, quindi in questo contesto è stato cruciale inserire le variabili esogene nel modello VARX-L considerandone i residui per la fase di analisi dell'incertezza previsiva (indicati con $\hat{\omega}_t$).

Algoritmo Bootstrap Forecasting

Successivamente la previsione della componente ciclica è stata effettuata attraverso una procedura ricorsiva, dove i valori osservati del ciclo economico sono stati utilizzati per generare le previsioni nei primi orizzonti temporali che di conseguenza alimentano iterativamente le previsioni successive consentendo di ottenere una previsione puntuale del ciclo economico per ogni serie storica, ovvero il valore previsto al tempo $t + 1$ viene utilizzato come lag per la previsione al tempo $t + 2$ e così via fino all'orizzonte $h=60$. La previsione puntuale del ciclo economico però non è sufficiente per rappresentare l'incertezza associata alle fluttuazioni cicliche, per questo motivo la quantificazione dell'incertezza previsiva è stata integrata nell'algoritmo dove è stata implementata una procedura Wild Block Bootstrap: in particolare i residui $\hat{\omega}_t$ del modello VARX-L sono stati ricampionati a blocchi e combinati con i valori fittati del modello per generare pseudo-serie cicliche, dove su ciascuna pseudo-serie il modello VARX penalizzato è stato interamente ristimato e utilizzato per produrre previsioni ricorsive sull'orizzonte previsivo. La procedura è stata ripetuta per $B = 1000$ replicazioni bootstrap, con un tempo computazionale totale pari a 9 minuti, in questo modo l'insieme delle previsioni ottenute costituiscono una distribuzione empirica delle traiettorie future del ciclo economico e a partire da tale distribuzione sono stati costruiti gli intervalli di confidenza che forniscono una valida misura quantitativa dell'incertezza previsiva. In questo modo con l'algoritmo utilizzato e proposto si è stati in grado di scomporre e prevedere la componente ciclica delle serie storiche unendo una modellizzazione multivariata avanzata e una valutazione completa dell'incertezza previsiva. Nei risultati previsivi ottenuti (Figure 32 e 33), mostrano complessivamente un andamento coerente delle dinamiche osservate per ciascuna fonte energetica e settore economico, in particolare le previsioni delle emissioni di CO₂ risultano ampiamente coerenti con l'evoluzione dei consumi energetici sia nel settore fossile che in quello rinnovabile. Le previsioni del ciclo economico elaborate nel lavoro di tesi forniscono già una base quantitativa solida per trarre delle considerazioni finali, la robustezza è stata confermata da un'accurata analisi diagnostica dei residui che confermano la stazionarietà e la corretta specificazione statistica. Questo per affermare che il lavoro di forecasting è stato fondamentale per sottolineare l'importanza di una pipeline metodologica robusta i cui dettagli e conclusioni vengono discussi nel paragrafo finale.




Figura 32: Previsioni energia consumata (ciclo economico)




Figura 33: Previsioni emissioni di CO₂ (ciclo economico)

Conclusioni

Il presente lavoro di tesi si è collocato in un quadro metodologico riguardante l'applicazione di modelli attraverso la metodologia BigVAR applicato al contesto energetico degli Stati Uniti con focus principale sui fondamenti teorici proposti da Nicholson et al. (2017, 2020), essenziali per superare il problema della dimensionalità. I modelli tradizionali esposti VAR e VARX sono soggetti a sovra-parametrizzazione che cresce smisuratamente con il numero di serie storiche che vengono incluse nel modello, quindi l'utilizzo delle regolarizzazioni strutturate ha permesso di imporre delle gerarchie nei ritardi per garantire la selezione di relazioni dinamiche rilevanti.

Come primo passaggio fondamentale è stato quello di effettuare un'analisi esplorativa approfondita per poter utilizzare le serie storiche nei modelli multivariati, un requisito essenziale è stato quello di rendere le serie storiche stazionarie per rispettare e garantire la validità statistica delle stime gestendo la non-stazionarietà, dovuta da trend da stagionalità e da potenziali break strutturali, attraverso l'utilizzo del metodo TRAMO-SEATS e della letteratura riguardante il filtraggio e la decomposizione delle serie storiche grazie al contributo di Maranzano e Pelagatti (2025) adottando il filtro Hodrick-Prescott with Jumps (HPJ) che è in grado di assorbire automaticamente i break strutturali associati a eventi globali. Successivamente, una volta ottenute le serie stazionarie rappresentative del ciclo economico, è stato possibile applicare e svolgere un confronto diretto tra i modelli tradizionali e i modelli regolarizzati BigVAR: i risultati ottenuti mostrano capacità predittive soddisfacenti, con prestazioni superiori della modellizzazione BigVAR con alcune divergenze per le fonti rinnovabili che risultano essere poco volatili nel lungo periodo rispetto alle fonti fossili.

La validazione dei risultati finali è stata condotta rigorosamente confrontando le performance out-of-sample e mediante l'analisi delle previsioni future per ogni serie storica che è stata considerata e analizzata. In questa fase si è prestata particolare attenzione alle criticità tipiche della modellizzazione delle serie storiche come il rischio di over-fitting o la sovra-parametrizzazione, seguendo le indicazioni di Hewamalage et al. (2023), che evidenziano come l'accuratezza delle previsioni non dipende solo dalla complessità del modello ma anche dalla correttezza nella fase di analisi e nella fase di valutazione dei modelli stessi.

Sul piano energetico e ambientale, i risultati e le previsioni indicano una continuazione coerente con il processo di transizione energetica in atto dove da una parte le fonti fossili si comportano come un sistema maturo e solido dove la storia passata risulta essere il miglior predittore, questo è evidenziato dalla dominanza della regolarizzazione HVAR per le fonti fossili osservate. Dall'altra parte le fonti rinnovabili emergono come un settore "più giovane" e fortemente guidato da fattori esterni, poiché la loro dinamica interna non è spiegata dalle interazioni passate, ma risponde in modo diretto a shock macroeconomici e driver esogeni evidenziato dalla dominanza della regolarizzazione VARX-L che permette di ottenere delle performance out-of-sample migliori: questo non significa che le fonti fossili non siano guidate da fattori economici e da driver esogeni ma le fonti rinnovabili lo sono in modo molto più diretto e marcato.

In sintesi, questo lavoro di tesi dimostra che l'applicazione dei modelli per serie storiche multivariate dipende soprattutto dalla combinazione tra rigore e flessibilità statistica, come suggerito nella revisione di Otto, Fassò e Maranzano (2024) dove espongono che l'utilizzo di procedure di stima regolarizzata non è legata solo ad una scelta tecnica ma risulta essere una necessità metodologica per l'analisi di processi temporali elaborati. Le conclusioni ottenute non solo confermano la validità dei modelli ad alta dimensionalità BigVAR applicata a dati reali provenienti dagli Stati Uniti, ma una volta che si comprendono questi strumenti possono porre delle basi per futuri sviluppi per trattare la transizione energetica, che a tutti gli effetti appare come un processo interpretabile e monitorabile nel tempo, offrendo un possibile supporto quantitativo per affrontare l'incertezza climatica ed economica che potrebbe susseguirsi nel corso del tempo.

Bibliografia

Paper Scientifici

Medeiros M. C., Mendes E. F. (2016), L_1 -regularization of high-dimensional time-series models with non-Gaussian and heteroskedastic errors, in *Journal of Econometrics*, 191, pp. 255-271.

Nicholson W. B., Matteson D. S., Bien J. (2017), VARX-L: Structured regularization for large vector autoregressions with exogenous variables, in *International Journal of Forecasting*, 33, pp. 627-651.

Nicholson W. B., Matteson D. S., Bien J. (2017), BigVAR: Tools for Modeling Sparse High-Dimensional Multivariate Time Series, *arXiv preprint*, arXiv:1702.07094.

Nicholson W. B., Wilms I., Matteson D. S., Bien J. (2020), High Dimensional Forecasting via Interpretable Vector Autoregression, in *Journal of Machine Learning Research*, 21, pp. 1-52.

Lee J. H., Shi Z., Gao Z. (2022), On LASSO for Predictive Regression, in *Journal of Econometrics*, 229, pp. 322-349.

Ackermann K., Bergmeir C., Hewamalage H. (2023), Forecast Evaluation for Data Scientists: common pitfalls and best practices, in *Data Mining and Knowledge Discovery*, 37, pp. 788-832.

Fassò A., Maranzano P., Otto P. (2024), A review of regularised estimation methods and cross-validation in spatiotemporal statistics, in *Statistical Surveys*, 18, pp. 299-340.

Maranzano P., Pelagatti M. (2025), A Hodrick–Prescott filter with automatically selected breaks, in *Economic Modelling*, 150, pp. 107132.

Libri

Wei William W.S. (2005), Time Series Analysis: Univariate and Multivariate Methods, *Pearson*, 2nd edition.

Lütkepohl, H. (2005). New Introduction to Multiple Time Series Analysis, *Springer*.

Shumway R. H., Stoffer D. S. (2017), Time Series Analysis and Its Applications: with R examples, *Springer*, 4th edition.

Pacchetti R

tidyverse: <https://cran.r-project.org/web/packages/tidyverse/>

lubridate: <https://cran.r-project.org/web/packages/lubridate/>

tsibble: <https://cran.r-project.org/web/packages/tsibble/>

forecast: <https://cran.r-project.org/web/packages/forecast/>

seastests: <https://cran.r-project.org/web/packages/seastests/>

tseries: <https://cran.r-project.org/web/packages/tseries/>

urca: <https://cran.r-project.org/web/packages/urca/>

seasonal: <https://cran.r-project.org/web/packages/seasonal/>

tramo-seats: <https://cran.r-project.org/web/packages/RJDemetra/>

hodrick–prescott with jumps: <https://cran.r-project.org/web/packages/jumps/>

vars: <https://cran.r-project.org/web/packages/vars/>

bigVAR: <https://cran.r-project.org/web/packages/BigVAR/>

Appendice A: Risultati analisi esplorativa serie storiche




Figura 1.A: Energy-serie storiche di partenza




Figura 2.A: Energy-serie storiche ciclo economico



Figura 3.A: CO₂-serie storiche di partenza




Figura 4.A: CO₂-serie storiche ciclo economico

Appendice B: metodologia BigVAR




Figura 1.B: Energy-Modello HVAR struttura Componentwise




Figura 2.B: Energy-Modello HVAR struttura Own/Other




Figura 3.B: Energy-Modello HVAR struttura Elementwise




Figura 4.B: CO₂-Modello HVAR struttura Componentwise




Figura 5.B: CO₂-Modello HVAR struttura Own/Other




Figura 6.B: CO₂-Modello HVAR struttura Elementwise

Appendice C: Bootstrap Forecasting

Algorithm 1 Parametric Bootstrap for Forecasting

Input: $t = 1, \dots, T$

Y_t : endogenous time series ($T \times k$)

X_t : exogenous time series ($T \times m$)

h : forecast horizon

Setup:

B : number of bootstrap iterations

L : block length for Wild Bootstrap

Phase 1: Original Pipeline and Residual Extraction

- [A] $Y_t \xrightarrow{\text{TRAMO-SEATS}} (\hat{C}T_t, \hat{S}_t) \rightarrow (\hat{C}T_{t+h}, \hat{S}_{t+h}) \quad \triangleright \text{Extract residuals } \hat{\epsilon}_t$
 $\rightarrow \hat{C}T_t[*]\hat{C}T_{t+h} \xrightarrow{\text{Forecast HPJ}} \hat{T}_{t+h}$
[B] $\hat{C}T_t \xrightarrow{\text{HPJ Filter}} (\hat{\hat{C}}_t, \hat{\hat{T}}_t)$
[C] $(\hat{\hat{C}}_t, X_t) \xrightarrow{\text{BigVAR}} \hat{\hat{C}}_t \xrightarrow{\text{BigVAR}} \hat{\hat{C}}_{t+h} \quad \triangleright \text{Extract residuals } \hat{\omega}_t$
[D] $X_t \xrightarrow{\text{SARIMA}} \hat{X}_t \xrightarrow{\text{SARIMA}} \hat{X}_{t+h} \quad \triangleright \text{Extract residuals } \hat{\eta}_t$
[E] **Point Forecast:** $\hat{Y}_{t+h} = \hat{S}_{t+h} + \hat{T}_{t+h} + \hat{\hat{C}}_{t+h}$

for $b = 1$ to B do

Wild Block Bootstrap resampling:

$$(\hat{\eta}_t, \hat{\omega}_t, \hat{\epsilon}_t) \xrightarrow{\text{Resample}} (\eta_t^{(b)}, \omega_t^{(b)}, \epsilon_t^{(b)})$$

Generation of Bootstrap Pseudo-series:

$$\hat{\eta}_t \xrightarrow{\text{Resample}} \eta_t^{(b)} \xrightarrow{\text{SARIMA}} X_t^{(b)}$$

$$\hat{\omega}_t \xrightarrow{\text{Resample}} \omega_t^{(b)} \xrightarrow{\text{BigVAR}} \hat{\hat{C}}_t^{(b)}$$

$$\hat{\epsilon}_t \xrightarrow{\text{Resample}} \epsilon_t^{(b)} \xrightarrow{\text{Equation}} Y_t^{(b)} = \hat{\hat{C}}_t^{(b)} + \hat{T}_t + \hat{S}_t + \epsilon_t^{(b)} \quad \triangleright \text{Reconstruct pseudo-data}$$

Phase 2: Full Pipeline Re-estimation:

Apply steps [A] through [E] on the pseudo-data $(X_t^{(b)}, Y_t^{(b)})$ to obtain $\hat{Y}_{t+h}^{(b)}$

end for

Output:

Bootstrap Confidence Intervals from distribution $\{\hat{Y}_{t+h}^{(b)}\}_{b=1}^B$

$$MSE = \frac{1}{B} \sum_{b=1}^B (\hat{Y}_{t+h}^{(b)} - \hat{Y}_{t+h})^2$$

Figura 1.C: Algoritmo bootstrap per la parte di previsione